

高级数值分析题目 (解答)

按原文档编号逐题作答, 题面从略.

记号约定.

- $\mathbf{A}^T$ 表示 $\mathbf{A}$ 的转置, $\mathbf{A}^*$ 表示共轭转置; $\|\cdot\|_2$ 表示向量 2-范数或矩阵谱范数, $\|\cdot\|_F$ 为 Frobenius 范数;
- 对对称正定阵 $\mathbf{A}$, $\|\mathbf{x}\|_{\mathbf{A}} = \sqrt{\mathbf{x}^T \mathbf{A} \mathbf{x}}$ 称为 $\mathbf{A}$ -(椭圆) 范数或能量范数;
- 第二, 三章题中出现的 $\|\mathbf{r}\|_{(\mathbf{A}^{-1})^{-1/2}}$, 按“由 $\mathbf{A}^{-1}$ 诱导的范数”理解, 即

$$\|\mathbf{r}\|_{(\mathbf{A}^{-1})^{-1/2}}^2 = \left\| \mathbf{A}^{-1/2} \mathbf{r} \right\|_2^2 = \mathbf{r}^T \mathbf{A}^{-1} \mathbf{r} = \|\mathbf{r}\|_{\mathbf{A}^{-1}}^2,$$

这正是残量的能量范数 (它与能量泛函相差一个常数);

- 按题中脚注: SD 表示最速下降法 (Steepest Descent), CG 表示共轭梯度法 (Conjugate Gradient), $\mathcal{K}_k(\mathbf{A}, \mathbf{b}) = \text{span}\{\mathbf{b}, \mathbf{A}\mathbf{b}, \dots, \mathbf{A}^{k-1}\mathbf{b}\}$ 为 Krylov 子空间;
- $\mathbf{Q}^* \mathbf{A} \mathbf{Q}$ 中 $\mathbf{Q}$ 为酉 (正交) 阵时称 $\mathbf{A}$ 与 $\mathbf{Q}^* \mathbf{A} \mathbf{Q}$ 正交相似 (酉相似).
- 除非特别说明, 本文涉及的 Krylov 子空间方法, CG 的有限步终止, QR 分解以及正交性等理论结论均在精确算术框架下讨论; 在实际浮点计算中, 由于舍入误差的影响, 正交性以及有限步终止等性质一般只能近似成立.

1 矩阵特征值问题的计算

1. 两个列空间张成的夹角 (2-范数)

记 $\mathbf{X} = \text{Range}(\mathbf{A})$, $\mathbf{Y} = \text{Range}(\mathbf{B})$, 它们是 $\mathbb{R}^3$ 的两个 2 维子空间. 由于 $\mathbf{A}, \mathbf{B}$ 的列向量本身已经标准正交, 故可直接取 $\mathbf{Q}_A = \mathbf{A}$, $\mathbf{Q}_B = \mathbf{B}$. 两个子空间的主角 $\theta_1 \leq \theta_2$ 由两个标准正交基的内积矩阵的奇异值给出:

$$\cos \theta_k = \sigma_k(\mathbf{Q}_A^T \mathbf{Q}_B), \quad k = 1, 2 \quad (\sigma_1 \geq \sigma_2).$$

计算

$$\mathbf{Q}_A^T \mathbf{Q}_B = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix} \begin{pmatrix} -\frac{\sqrt{2}}{2} & 0 \\ \frac{\sqrt{2}}{2} & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} -\frac{\sqrt{2}}{2} & 0 \\ \frac{\sqrt{2}}{2} & 0 \end{pmatrix},$$

$$(\mathbf{Q}_A^T \mathbf{Q}_B)^T (\mathbf{Q}_A^T \mathbf{Q}_B) = \begin{pmatrix} \frac{1}{2} + \frac{1}{2} & 0 \\ 0 & 0 \end{pmatrix} = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \implies \sigma_1 = 1, \quad \sigma_2 = 0.$$

于是 $\cos \theta_1 = 1$, $\cos \theta_2 = 0$, 即

$$\theta_1 = 0, \quad \theta_2 = \frac{\pi}{2}.$$

按照题目中“子空间夹角取最大主角”的定义, 两个子空间的夹角即为最大的主角 θ_2 (即 $\cos \theta = \sigma_{\min}(\mathbf{Q}_A^T \mathbf{Q}_B)$):

$$\theta(\mathbf{X}, \mathbf{Y}) = \arccos \sigma_2 = \frac{\pi}{2} = 90^\circ.$$

(若按“最小主角”定义, 则夹角为 $\theta_1 = 0$; 两种约定的差别仅在于取最大还是最小主角, 本题的两个主角为 0 与 $\pi/2$.)

几何核对. $\mathbf{X} = \text{span}\{\mathbf{e}_1, \mathbf{e}_2\}$ 是平面 $z = 0$, 而 $\mathbf{Y} = \text{span}\{(-1, 1, 0)^T/\sqrt{2}, \mathbf{e}_3\}$ 是平面 $y = -x$. 二者交于直线 $\text{span}\{(1, -1, 0)^T\}$, 对应主角 $\theta_1 = 0$; 又 $\mathbf{e}_3 \perp \mathbf{X}$, $(1, 1, 0)^T/\sqrt{2} \perp \mathbf{Y}$, 且两平面的法向量 $(0, 0, 1)^T$ 与 $(1, 1, 0)^T/\sqrt{2}$ 正交, 故两平面的二面角为 90° , 对应 $\theta_2 = \pi/2$. 等价地, 若 $\mathbf{P}_X, \mathbf{P}_Y$ 为正交投影阵, 则

$$\sin \theta_2 = \|(I - \mathbf{P}_X)\mathbf{P}_Y\|_2 = 1,$$

同样得到夹角 $\pi/2$.

2. 用 Householder 变换化 $\mathbf{A}$ 为上 Hessenberg 阵

$$\mathbf{A} = \begin{pmatrix} 0 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 0 \end{pmatrix}, \quad n = 3, \text{ 只需把第 1 列次对角线以下的元素 (即 } a_{31}) \text{ 消为零.}$$

第一步. 取 $\mathbf{x} = (a_{21}, a_{31})^T = (1, 1)^T$, $\|\mathbf{x}\|_2 = \sqrt{2}$. 令

$$\sigma = \text{sgn}(x_1) \|\mathbf{x}\|_2 = \sqrt{2}, \quad \mathbf{u} = \mathbf{x} + \sigma \mathbf{e}_1 = \begin{pmatrix} 1 + \sqrt{2} \\ 1 \end{pmatrix},$$

$$\mathbf{H} = \mathbf{I} - \frac{2\mathbf{u}\mathbf{u}^T}{\mathbf{u}^T\mathbf{u}} = \begin{pmatrix} -\frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \\ \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{pmatrix}, \quad \mathbf{H}\mathbf{x} = -\sigma \mathbf{e}_1 = \begin{pmatrix} -\sqrt{2} \\ 0 \end{pmatrix}.$$

取 $\mathbf{H}_1 = \text{diag}(1, \mathbf{H})$ ($\mathbf{H}_1^T = \mathbf{H}_1$, 且 $\mathbf{H}_1^T \mathbf{H}_1 = \mathbf{I}$). 于是

$$\mathbf{H}_1 \mathbf{A} = \begin{pmatrix} 0 & 1 & 1 \\ -\sqrt{2} & -\sqrt{2} & -\frac{\sqrt{2}}{2} \\ 0 & 0 & -\frac{\sqrt{2}}{2} \end{pmatrix},$$

再作相似变换

$$\mathbf{A}_2 := \mathbf{H}_1 \mathbf{A} \mathbf{H}_1 = \begin{pmatrix} 0 & -\sqrt{2} & 0 \\ -\sqrt{2} & \frac{3}{2} & \frac{1}{2} \\ 0 & \frac{1}{2} & -\frac{1}{2} \end{pmatrix},$$

其中 $\mathbf{A}_2(3, 1) = 0$, 故 $\mathbf{A}_2$ 已是上 Hessenberg 阵, 且因为 $\mathbf{A}$ 对称, 它实际上是对称三对角阵.

相应的正交阵为

$$Q = H_1^T = H_1 = \begin{pmatrix} 1 & 0 & 0 \\ 0 & -\frac{\sqrt{2}}{2} & -\frac{\sqrt{2}}{2} \\ 0 & -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{pmatrix}, \quad Q^T A Q = A_2.$$

由于 $H_1^T = H_1$ 且 $H_1^T H_1 = I$, 这里所用的 H_1 是正交 (且对称) 矩阵, 故 $Q^T A Q$ 是 A 的正交相似变换, 特征值保持不变; 同时 H_1 只作镜面反射, 不是一般的初等行变换.

3. A 的 Gerschgorin 圆盘

$$A = \begin{pmatrix} 3 & 1 & 2 \\ 1 & 0 & 5 \\ 1 & 3 & 6 \end{pmatrix}.$$

按行的 Gerschgorin 圆盘 $G_i = \{z : |z - a_{ii}| \leq \sum_{j \neq i} |a_{ij}|\}$ 为

$$G_1 : |z - 3| \leq |1| + |2| = 3, \quad G_2 : |z - 0| \leq |1| + |5| = 6, \quad G_3 : |z - 6| \leq |1| + |3| = 4.$$

按列 (即对 A^T 用上述结论) 的圆盘为

$$G^{(1)} : |z - 3| \leq 2, \quad G^{(2)} : |z| \leq 4, \quad G^{(3)} : |z - 6| \leq 7.$$

由 Gerschgorin 定理, A 的全部特征值含于行圆盘之并 $\sigma(A) \subset G_1 \cup G_2 \cup G_3$, 也含于列圆盘之并. 根据 Gerschgorin 圆盘定理, 矩阵的每一个特征值至少属于一个行圆盘, 也至少属于一个列圆盘.

由于 $G_1 \subset G_2$ ($|z - 3| \leq 3 \Rightarrow |z| \leq 6$), 第一个圆盘是多余的; 又 $G_2 \cap G_3 \ni 3 \neq \emptyset$, 三个圆盘构成一个连通区域, 故由 Gerschgorin 定理只能断言

$$\sigma(A) \subset \{|z| \leq 6\} \cup \{|z - 6| \leq 4\},$$

即全部特征值位于这一个连通并集中, 不能把特征值进一步分离; 由此还得到谱半径的估计

$$\rho(A) \leq \max_i \left(|a_{ii}| + \sum_{j \neq i} |a_{ij}| \right) = \max\{6, 6, 10\} = 10.$$

(注意 $0 \in G_2$, 故仅用 Gerschgorin 定理不能判定 A 非奇异; 实际上 $\det A = -40 \neq 0$.)

数值核对. 特征多项式为

$$\det(\lambda I - A) = \lambda^3 - 9\lambda^2 + 0 \cdot \lambda + 40,$$

三个特征值约为

$$\lambda_1 \approx 8.4382, \quad \lambda_2 \approx 2.4762, \quad \lambda_3 \approx -1.9144,$$

它们确实都落在上述并集之内 ($8.4382 \in \{|z - 6| \leq 4\}$, 另两个落在 $\{|z| \leq 6\}$ 内).

4. 正交迭代法产生的 Q_k 是 A^k 的 QR 分解的 Q 因子

正交迭代法: 取 $Q_0 = I$, 对 $k = 1, 2, \dots$ 计算 $Z_k = AQ_{k-1}$, 并作 (约化)QR 分解

$$Z_k = AQ_{k-1} = Q_k R_k,$$

其中 Q_k 为酉 (正交) 阵, R_k 为上三角阵.

证明. 对 k 作归纳, 证明

$$A^k = Q_k R^{(k)}, \quad R^{(k)} := R_k R_{k-1} \cdots R_1 \text{ (上三角阵)}.$$

$k = 1$ 时 $A = AQ_0 = Q_1 R_1$, 成立. 设 $A^k = Q_k R^{(k)}$, 则

$$A^{k+1} = A \cdot A^k = AQ_k R^{(k)} = Q_{k+1} R_{k+1} R^{(k)} = Q_{k+1} R^{(k+1)},$$

归纳完成.

于是 $A^k = Q_k R^{(k)}$ 就是 A^k 的一个 QR 分解: Q_k 酉, $R^{(k)}$ 上三角. 这里需要补充 QR 分解的唯一性条件: 对于非奇异矩阵 A , 若规定 R 的对角元满足 $r_{ii} > 0$, 则 QR 分解 $A = QR$ 是唯一的; 否则 Q 与 R 的符号可以同时作相应调整 (即 $Q \rightarrow QD$, $R \rightarrow DR$, 其中 D 为对角酉阵), QR 分解并不严格唯一. 因此当 A 非奇异 (从而 A^k 非奇异), 并把 $R^{(k)}$ 的对角元规范为正时, QR 分解唯一, 故 Q_k 恰为 A^k 的约化 QR 分解中的 Q 因子. $\square$

注. 该结论的实质是子空间迭代:

$$\text{Range}(A^k) = A^k \text{Range}(Q_0),$$

即正交迭代法每一步都在跟踪子空间序列 $\text{Range}(A^k)$. 若 A 奇异, 则 A^k 的 QR 分解不唯一, 但仍存在以 Q_k 为 Q 因子的 QR 分解.

5. QR 方法的迭代方程与一步迭代结果

迭代方程. 无位移 QR 方法:

$$A_1 = A; \quad A_k = Q_k R_k \text{ (QR 分解)}, \quad A_{k+1} = R_k Q_k = Q_k^T A_k Q_k.$$

带位移 μ_k 的 QR 方法:

$$A_1 = A; \quad A_k - \mu_k I = Q_k R_k, \quad A_{k+1} = R_k Q_k + \mu_k I.$$

一步迭代. 对 $A = \begin{pmatrix} 1 & 1 & 1 \\ 2 & -1 & -1 \\ 2 & -4 & 5 \end{pmatrix}$, 用 Householder 变换作 QR 分解:

$$x = \begin{pmatrix} 1 \\ 2 \\ 2 \end{pmatrix}, \quad \|x\|_2 = 3, \quad u_1 = x + 3e_1 = \begin{pmatrix} 4 \\ 2 \\ 2 \end{pmatrix}, \quad H_1 = I - \frac{2u_1 u_1^T}{u_1^T u_1} = \frac{1}{3} \begin{pmatrix} -1 & -2 & -2 \\ -2 & 2 & -1 \\ -2 & -1 & 2 \end{pmatrix},$$

$$H_1 A = \begin{pmatrix} -3 & 3 & -3 \\ 0 & 0 & -3 \\ 0 & -3 & 3 \end{pmatrix},$$

再取 $H_2 = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix}$ (交换第 2, 3 行) 消去 (3, 2) 元, 得

$$R = H_2 H_1 A = \begin{pmatrix} -3 & 3 & -3 \\ 0 & -3 & 3 \\ 0 & 0 & -3 \end{pmatrix}, \quad Q = H_1^T H_2^T = H_1 H_2 = \frac{1}{3} \begin{pmatrix} -1 & -2 & -2 \\ -2 & -1 & 2 \\ -2 & 2 & -1 \end{pmatrix}.$$

其中 H_2 是置换矩阵, 满足 $H_2^T H_2 = I$, 故 H_2 是正交矩阵 (它不是一般的初等行变换). 容易验证 $Q^T Q = I$ 且 $QR = A$. 于是

$$A_2 = RQ = \begin{pmatrix} 1 & -1 & 5 \\ 0 & 3 & -3 \\ 2 & -2 & 1 \end{pmatrix}.$$

核对. $\text{tr } A_2 = 1 + 3 + 1 = 5 = \text{tr } A$, 且 $\det A_2 = \det A = -27$, 符合相似变换的不变量要求. (若把 R 的对角元规范为正, 则 Q 整体变号而 R 也整体变号, $A_2 = RQ$ 不变.)

6. A^k 的 QR 分解与逐步因子的乘积

记号区分 (务必分清“幂”与“迭代矩阵”). 本节涉及两个容易混淆的对象:

$$A^k = \underbrace{A \cdot A \cdots A}_{k \text{ 个}} \quad (A \text{ 的 } k \text{ 次幂}), \quad A_k \quad (\text{QR 方法的第 } k \text{ 个迭代矩阵}).$$

按第 5 题的迭代方程 $A_1 = A$, $A_k = Q_k R_k$, $A_{k+1} = R_k Q_k = Q_k^* A_k Q_k$, 一般地 $A_{k+1} \neq A A_k$ (例如 $k=1$ 时 $A_2 = R_1 Q_1$, 而 $A A_1 = A^2$, 二者一般不相等), 因此下面归纳证明中出现的是幂的乘法 $A^{k+1} = A \cdot A^k$, 它与迭代关系 $A_{k+1} = R_k Q_k$ 是两件不同的事, 不可混用. 记

$$U_k := Q_1 Q_2 \cdots Q_k \quad (\text{酉阵}), \quad R^{(k)} := R_k R_{k-1} \cdots R_1 \quad (\text{上三角阵}).$$

结论. 对一切 $k \geq 1$ 成立两个不同的关系:

$$A^k = U_k R^{(k)} = (Q_1 Q_2 \cdots Q_k) (R_k R_{k-1} \cdots R_1),$$

$$A_k = U_{k-1}^* A U_{k-1}.$$

前者说明 $U_k, R^{(k)}$ 分别是 A 的 k 次幂 A^k 的 QR 分解中的 Q 因子与 R 因子 (唯一性同第 4 题); 后者说明迭代矩阵 A_k 与 A 正交相似.

证明. 先建立一个基本关系. 由 $A_{j+1} = Q_j^* A_j Q_j$ 归纳可得 $A_j = U_{j-1}^* A U_{j-1}$, 于是

$$A U_j = U_j A_{j+1} = U_j Q_{j+1} R_{j+1} = U_{j+1} R_{j+1} \quad (j \geq 0, U_0 = I).$$

再对 k 归纳: $k=1$ 时 $A = A U_0 = U_1 R_1$ 成立; 设 $A^k = U_k R^{(k)}$, 则

$$A^{k+1} = A \cdot A^k = (A U_k) R^{(k)} = U_{k+1} R_{k+1} R_k \cdots R_1 = U_{k+1} R^{(k+1)},$$

归纳完成; 第二个关系 $A_k = U_{k-1}^* A U_{k-1}$ 已在上面一并得到. $\square$

注. 上述证明只用到幂的乘法 $A^{k+1} = A \cdot A^k$ 与基本关系 $A U_j = U_{j+1} R_{j+1}$, 并没有使用 $A_{k+1} = A A_k$ (该式一般不成立). 等价地, 也可逐个使用 $R_j Q_j = A_{j+1} = Q_{j+1} R_{j+1}$ 把

$A^{k+1} = Q_1 R_1 Q_1 Q_2 \cdots Q_k R_k \cdots R_1$ 中的 R_j 依次向右“推”至末尾, 同样得到 $U_{k+1} R^{(k+1)}$. (与第 4 题记号的关系: 第 4 题正交迭代法中的酉阵 Q_k 即此处的 U_k , 因为 $AU_{k-1} = U_k R_k$ 正是正交迭代法的递推式; 两题只是记号不同, 结论一致.)

关于次序的说明. 上三角阵的乘积一般不可交换, 故 R 因子必须按产生的先后逆序相乘, 即 $R^{(k)} = R_k R_{k-1} \cdots R_1$, 一般不能写成 $R_1 R_2 \cdots R_k$, 因为上三角矩阵一般不满足交换律, 即 $R_i R_j \neq R_j R_i$. 题面把 $R^{(k)}$ 写成 $R_1 \cdots R_k$, 应理解为“按产生顺序从左到右排列各因子”, 即把 R_j 的编号取为“在 A^k 的 R 因子中自左至右第 j 个因子”; 在这种编号下两种写法一致. (Q 因子由于都是酉阵且次序与推导一致, 不存在这个问题.)

7. 上 Hessenberg 形与三对角形的保持性

引理. 设 H 为上 Hessenberg 阵 (即 $i > j + 1$ 时 $h_{ij} = 0$), T 为上三角阵, 则 HT 与 TH 都是上 Hessenberg 阵.

证明. $(HT)_{ij} = \sum_k h_{ik} t_{kj}$, 其非零项需 $k \geq i - 1$ (H) 且 $k \leq j$ (T), 故 $i - 1 \leq j$, 即 $i \leq j + 1$; $(TH)_{ij} = \sum_k t_{ik} h_{kj}$, 非零项需 $k \geq i$ 且 $k \leq j + 1$, 同样得 $i \leq j + 1$. $\square$

定理 1 (上 Hessenberg 形保持). 若 A 为上 Hessenberg 阵, 且 QR 方法中出现的 A_k (或 $A_k - \mu_k I$) 非奇异, 则一切 A_k 都是上 Hessenberg 阵.

证明. 设 A_k 为上 Hessenberg 且 $A_k = Q_k R_k$ (R_k 可逆), 则 $Q_k = A_k R_k^{-1}$, 其中 R_k^{-1} 为上三角阵, 由引理知 Q_k 是上 Hessenberg 阵; 再由引理, $A_{k+1} = R_k Q_k$ 是上 Hessenberg 阵. 归纳即得结论. 带位移时把 A_k 换成仍为上 Hessenberg 的 $A_k - \mu_k I$ 即可 (μ_k 不是特征值时它非奇异). $\square$

另证 (用 Givens 变换, 不需要非奇异性假设). 上 Hessenberg 阵的 QR 分解可用 $n - 1$ 个 Givens 旋转 $G_1, \dots, G_{n-1}$ 实现, 其中 G_i 只作用在第 $i, i + 1$ 行并消去 $(i + 1, i)$ 元:

$$G_{n-1} \cdots G_1 A = R \text{ (上三角)}, \quad Q = G_1^T G_2^T \cdots G_{n-1}^T.$$

每个 G_i 本身是上 Hessenberg 阵, 而形如 G_i 的旋转之积仍是上 Hessenberg 阵 (因为 G_i 只在第 $i, i + 1$ 行有非平凡作用, 逐列考察可知 (i, j) 元在 $i > j + 1$ 时恒为零), 故 Q 为上 Hessenberg 阵, 从而 $A_{k+1} = RQ$ 为上三角阵与上 Hessenberg 阵之积, 仍为上 Hessenberg 阵.

定理 2 (三对角形保持). 若 A 是对称三对角阵, 则 QR 方法产生的一切 A_k 都是三对角阵.

证明. 由 $A_k = U_{k-1}^* A U_{k-1}$ (第 6 题推论) 知 A_k 与 A 正交相似, 故 A_k 仍为对称阵; 又由定理 1, A_k 为上 Hessenberg 阵; 对称的上 Hessenberg 阵必为三对角阵, 故 A_k 是三对角阵. $\square$

注 (非对称情形结论不成立). 若去掉对称性, 题中“三对角 $\Rightarrow$ 迭代后仍三对角”的结论是不对的. 反例: 取三对角阵

$$T = \begin{pmatrix} 1 & 2 & 0 \\ 3 & 4 & 5 \\ 0 & 6 & 7 \end{pmatrix},$$

作一步 QR 迭代 (取 R 对角元为正), 得

$$T_2 = RQ = \begin{pmatrix} 5.2 & 4.8850073 & -1.0939393 \\ 5.7236352 & 6.5582418 & 2.6097478 \\ 0 & 2.2935201 & 0.2417582 \end{pmatrix},$$

其中 $(1, 3)$ 元为 $-1.0939393 \neq 0$, 故 T_2 只是上 Hessenberg 阵而不再是三对角阵. (原因: $(RQ)_{13} = r_{11}q_{13} + r_{12}q_{23} + r_{13}q_{33}$ 一般不为零, 上三角阵乘上 Hessenberg 阵只保证“上 Hessenberg”, 不保证“上双对角”.) 因此该结论应以“ A 为对称 (自伴) 三对角阵”为前提; 这也正是

对称矩阵情形下 QR 方法格外高效的原因. 总结: 一般上 Hessenberg 矩阵在 QR 迭代下保持上 Hessenberg 结构; 对于实对称矩阵, 由于对称性与上 Hessenberg 结构共同作用, 矩阵具有对称三对角结构, 并在 QR 迭代中保持该结构.

8. Rayleigh 商位移与 Wilkinson 位移

$$\mathbf{A} = \begin{pmatrix} 0 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 0 \end{pmatrix} \text{ (对称阵).}$$

Rayleigh 商位移. 一般地取 $\mu_k = \mathbf{x}^T \mathbf{A}_k \mathbf{x} / \mathbf{x}^T \mathbf{x}$; QR 方法中通常取 $\mathbf{x} = \mathbf{e}_n$, 即 $\mu_k = (\mathbf{A}_k)_{nn}$ (n 阶阵的右下角元). 本题

$$\mu_1 = a_{33} = 0.$$

Wilkinson 位移. 取 $\mathbf{A}_k$ 的右下角 2×2 子阵

$$\mathbf{B}_k = \begin{pmatrix} a_{n-1,n-1} & a_{n-1,n} \\ a_{n,n-1} & a_{nn} \end{pmatrix}, \quad d = \frac{a_{n-1,n-1} - a_{nn}}{2},$$

则 $\mathbf{B}_k$ 的两个特征值为 $a_{nn} + d \pm \sqrt{d^2 + a_{n,n-1}^2}$, 取其中离 a_{nn} 较近的一个作为位移:

$$\mu_k = a_{nn} + d - \operatorname{sgn}(d) \sqrt{d^2 + a_{n,n-1}^2} \quad (\text{约定 } \operatorname{sgn}(0) = 1).$$

本题 $\mathbf{B} = \begin{pmatrix} 1 & 1 \\ 1 & 0 \end{pmatrix}$, $\det(\lambda \mathbf{I} - \mathbf{B}) = \lambda^2 - \lambda - 1$, 特征值为 $\frac{1 \pm \sqrt{5}}{2}$; 与 $a_{33} = 0$ 较近的是 $\frac{1 - \sqrt{5}}{2} \approx -0.6180340$, 故

$$\mu_1^W = \frac{1 - \sqrt{5}}{2} \approx -0.6180340.$$

(用公式核对: $d = \frac{1-0}{2} = \frac{1}{2}$, $a_{n,n-1} = 1$, $\mu = 0 + \frac{1}{2} - \sqrt{\frac{1}{4} + 1} = \frac{1 - \sqrt{5}}{2}$, 一致.)

带 Wilkinson 位移的 QR 方法迭代格式. 设 $\mathbf{A}$ 已化为上 Hessenberg (对称时即三对角) 阵, $\mathbf{A}_1 = \mathbf{A}$, 对 $k = 1, 2, \dots$ 循环:

1. (收缩/降阶) 若 $|a_{n,n-1}^{(k)}| \leq \varepsilon(|a_{n-1,n-1}^{(k)}| + |a_{nn}^{(k)}|)$, 则置 $a_{n,n-1}^{(k)} = 0$, $a_{nn}^{(k)}$ 即为一个特征值的近似, 问题降为 $n-1$ 阶子阵, 转第 1 步;
2. (计算位移) 取 $\mathbf{A}_k$ 右下角 2×2 子阵, 令 $d_k = (a_{n-1,n-1}^{(k)} - a_{nn}^{(k)})/2$,

$$\mu_k = a_{nn}^{(k)} + d_k - \operatorname{sgn}(d_k) \sqrt{d_k^2 + (a_{n,n-1}^{(k)})^2};$$

(约定 $\operatorname{sgn}(0) = 1$)

3. (QR 分解) 作 QR 分解 $\mathbf{A}_k - \mu_k \mathbf{I} = \mathbf{Q}_k \mathbf{R}_k$;

4. (更新) $\mathbf{A}_{k+1} = \mathbf{R}_k \mathbf{Q}_k + \mu_k \mathbf{I}$, 返回第 1 步.

注. 本题 $\mathbf{A}$ 的特征值为 $-1, 1 + \sqrt{2}, 1 - \sqrt{2}$ (即 $-1, 2.4142, -0.4142$): 特征多项式为 $\lambda^3 - \lambda^2 - 3\lambda - 1$. Rayleigh 位移 $\mu = 0$ 恰使迭代退化为无位移 QR 方法, 收敛很慢; Wilkinson 位移 $(1 - \sqrt{5})/2 \approx -0.618$ 是右下角 2×2 子阵的较小特征值, 与真实特征值较为接近, 故能显著加速收敛. 需要说明的是, 只有在目标特征值为单特征值且迭代已进入相应的局部收敛区域等条件下, Wilkinson 位移才通常具有局部三次收敛性质.

9. 压缩稀疏格式到对角存储格式

由 $IA = (1, 3, 5, 6)$ 知 A 有 $4 - 1 = 3$ 行; 由 JA 中最大指标 4 知 A 有 4 列. 按 CSR (AA, JA, IA) 格式, 第 i 行的非零元为 $AA(IA(i) : IA(i+1) - 1)$, 对应列号为 JA 中同位置的元素:

第1行: $AA(1:2) = (1, 4)$, $JA(1:2) = (1, 3) \Rightarrow a_{11} = 1, a_{13} = 4$;

第2行: $AA(3:4) = (2, 6)$, $JA(3:4) = (2, 4) \Rightarrow a_{22} = 2, a_{24} = 6$;

第3行: $AA(5:5) = (3)$, $JA(5:5) = (3) \Rightarrow a_{33} = 3$.

即

$$A = \begin{pmatrix} 1 & 0 & 4 & 0 \\ 0 & 2 & 0 & 6 \\ 0 & 0 & 3 & 0 \end{pmatrix}_{3 \times 4}.$$

由于不同教材对 DIA 存储格式的具体排列约定可能不同, 以下按本题所采用的 DIA 存储约定排列各条对角线及其 offset.

对角存储格式 (DIA) 的定义. 用一个 $n \times n_{\text{diag}}$ 的数组 $DIAG$ 与一个长度 n_{diag} 的偏移数组 $IOFF$ 存储: 若 $IOFF(j) = d_j$, 则 $DIAG(i, j) = a_{i, i+d_j}$ ($1 \leq i \leq n$, 指标越界的位置补零或置占位符). A 只有两条非零对角线:

- 偏移 $d = 0$ (主对角线): $a_{11} = 1, a_{22} = 2, a_{33} = 3$;
- 偏移 $d = 2$ (第 2 条上对角线): $a_{13} = 4, a_{24} = 6$ (a_{35} 已越界, 补零).

故 A 的对角存储格式为

$$DIAG = \begin{pmatrix} 1 & 4 \\ 2 & 6 \\ 3 & 0 \end{pmatrix}_{3 \times 2}, \quad IOFF = \begin{pmatrix} 0 & 2 \end{pmatrix},$$

即第 1 列存主对角线, 第 2 列存偏移为 2 的对角线, 第 i 行对应矩阵的第 i 行, 故 DIA 数据数组共需

$$2 \times 3 = 6$$

个实数单元.

与 CSR 存储量的比较. 由 $IA = (1, 3, 5, 6)$ 知非零元个数为

$$\text{nnz} = IA(n+1) - 1 = IA(4) - 1 = 5,$$

故 CSR 所需的数组长度为

$$|AA| = |JA| = \text{nnz} = 5, \quad |IA| = n + 1 = 4, \quad \text{合计} \quad 5 + 5 + 4 = 14$$

个单元, 而不是 16. 因此本例中 DIA 的 6 个单元确实比 CSR 的 14 个单元更省, 可见当矩阵的非零对角线很少时对角存储更经济. (题面给出的 AA, JA 各列出了 6 个元素, 其中第 6 个元素 $AA(6) = 1, JA(6) = 1$ 并未被 IA 引用, 且与 $AA(1), JA(1)$ 重复, 属于冗余数据; 只有把它也计入数组长度时才会得到 $6 + 6 + 4 = 16$. 另外顺便指出: 本例矩阵只有 3 行 4 列, 满存储也只需 $3 \times 4 = 12$ 个单元, 故对小规模例子 CSR 在单元数上并不占优, 稀疏存储的优势要在规模较大时才体现出来.) 等价地也可以把两条对角线按行排成 $\begin{pmatrix} 0 & 0 & 4 & 6 \\ 1 & 2 & 3 & 0 \end{pmatrix}$, 偏移仍为 $(0, 2)$, 只是排列方式 (行/列优先) 不同.

10. 修正 Gram-Schmidt 正交化

算法 (MGS, 按列进行). 设 $\mathbf{a}_1, \dots, \mathbf{a}_n$ 线性无关:

```

for  $i = 1 : n$ 
     $\mathbf{v}_i := \mathbf{a}_i$ ;
    for  $j = 1 : i - 1$ 
         $r_{ji} := \mathbf{q}_j^* \mathbf{v}_i$ ;     $\mathbf{v}_i := \mathbf{v}_i - r_{ji} \mathbf{q}_j$ ;    (立即更新)
    end
     $r_{ii} := \|\mathbf{v}_i\|_2$ ;     $\mathbf{q}_i := \mathbf{v}_i / r_{ii}$ ;
end
    
```

输出标准正交组 $\{\mathbf{q}_i\}$ 与上三角阵 $\mathbf{R} = (r_{ij})$, 且 $\mathbf{A} = \mathbf{QR}$.

对给定向量组正交化.

$$\boldsymbol{\alpha}_1 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \quad \boldsymbol{\alpha}_2 = \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}, \quad \boldsymbol{\alpha}_3 = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}.$$

- $i = 1$: $\mathbf{v}_1 = \boldsymbol{\alpha}_1$, $r_{11} = \|\mathbf{v}_1\|_2 = 1$, $\mathbf{q}_1 = (1, 0, 0)^T$.
- $i = 2$: $\mathbf{v}_2 = \boldsymbol{\alpha}_2 = (1, 1, 0)^T$; $r_{12} = \mathbf{q}_1^T \mathbf{v}_2 = 1$, $\mathbf{v}_2 \leftarrow \mathbf{v}_2 - \mathbf{q}_1 = (0, 1, 0)^T$; $r_{22} = 1$, $\mathbf{q}_2 = (0, 1, 0)^T$.
- $i = 3$: $\mathbf{v}_3 = \boldsymbol{\alpha}_3 = (1, 1, 1)^T$; $r_{13} = \mathbf{q}_1^T \mathbf{v}_3 = 1$, $\mathbf{v}_3 \leftarrow (0, 1, 1)^T$; $r_{23} = \mathbf{q}_2^T \mathbf{v}_3 = 1$, $\mathbf{v}_3 \leftarrow (0, 0, 1)^T$; $r_{33} = 1$, $\mathbf{q}_3 = (0, 0, 1)^T$.

于是

$$\mathbf{q}_1 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}, \quad \mathbf{q}_2 = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix}, \quad \mathbf{q}_3 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}, \quad \mathbf{R} = \begin{pmatrix} 1 & 1 & 1 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{pmatrix}, \quad \mathbf{Q} = \mathbf{I}.$$

即 $\{\mathbf{q}_1, \mathbf{q}_2, \mathbf{q}_3\} = \{\mathbf{e}_1, \mathbf{e}_2, \mathbf{e}_3\}$, 且 $(\boldsymbol{\alpha}_1, \boldsymbol{\alpha}_2, \boldsymbol{\alpha}_3) = \mathbf{QR}$, $\mathbf{R}$ 恰好就是原矩阵 (因为原向量组构成的矩阵本身已是主对角元为正的上三角阵, 其 QR 分解自然是 $\mathbf{Q} = \mathbf{I}$).

修正 Gram-Schmidt 与经典 Gram-Schmidt 的等价性. 设经典 Gram-Schmidt (CGS) 为

$$r_{ji} = \mathbf{q}_j^* \mathbf{a}_i \quad (j < i), \quad \mathbf{v}_i = \mathbf{a}_i - \sum_{j < i} r_{ji} \mathbf{q}_j, \quad r_{ii} = \|\mathbf{v}_i\|_2, \quad \mathbf{q}_i = \mathbf{v}_i / r_{ii},$$

即系数一律用原始向量 $\mathbf{a}_i$ 计算; MGS 则在每一步用已更新的 $\mathbf{v}_i$ 计算系数. 证明二者在精确算术下给出完全相同的 $\mathbf{Q}$ 与 $\mathbf{R}$.

对 i 归纳证明: 当 MGS 完成第 j 个内循环 ($j = 0, 1, \dots, i - 1$) 后

$$\mathbf{v}_i^{(j)} = \mathbf{a}_i - \sum_{l=1}^j r_{li} \mathbf{q}_l = \mathbf{a}_i - \sum_{l=1}^j (\mathbf{q}_l^* \mathbf{a}_i) \mathbf{q}_l, \quad \text{且} \quad r_{li} = \mathbf{q}_l^* \mathbf{a}_i \quad (l \leq j). \quad (*)$$

$j = 0$ 时 $\mathbf{v}_i^{(0)} = \mathbf{a}_i$, 平凡成立. 设 $(*)$ 对 j 成立, 则由正交性 $\mathbf{q}_{j+1}^* \mathbf{q}_l = 0$ ($l \leq j$) 得

$$r_{j+1,i} = \mathbf{q}_{j+1}^* \mathbf{v}_i^{(j)} = \mathbf{q}_{j+1}^* \mathbf{a}_i - \sum_{l \leq j} (\mathbf{q}_l^* \mathbf{a}_i) \underbrace{\mathbf{q}_{j+1}^* \mathbf{q}_l}_{=0} = \mathbf{q}_{j+1}^* \mathbf{a}_i,$$

且 $\mathbf{v}_i^{(j+1)} = \mathbf{v}_i^{(j)} - r_{j+1,i} \mathbf{q}_{j+1} = \mathbf{a}_i - \sum_{l \leq j+1} (\mathbf{q}_l^* \mathbf{a}_i) \mathbf{q}_l$, 归纳完成. 这里用到 $\mathbf{q}_{j+1} \perp \mathbf{q}_1, \dots, \mathbf{q}_j$, 而 $\mathbf{q}_{j+1}$ 是由 $\mathbf{v}_{j+1}^{(j)}$ 单位化得到的, 由归纳假设 $\mathbf{v}_{j+1}^{(j)}$ 已与 $\mathbf{q}_1, \dots, \mathbf{q}_j$ 正交, 故正交性成立 (这正是 MGS 与 CGS 在精确算术下等价的根本原因).

于是 MGS 算出的 r_{li} 与 CGS 完全相同, 进而 $\mathbf{v}_i^{(i-1)}, r_{ii}, \mathbf{q}_i$ 也完全相同. 故两种算法在精确算术下产生同样的 QR 分解. $\square$

注. 二者的差别只在浮点运算下: CGS 由于用原始向量计算系数, 舍入误差使正交性损失可达 $O(\kappa_2^2(\mathbf{A})\varepsilon)$; MGS 的损失仅为 $O(\kappa_2(\mathbf{A})\varepsilon)$, 故数值上 MGS 明显更稳定.

11. Rayleigh–Ritz 投影加速与基本 Arnoldi 算法

基本思想. 对大型稀疏矩阵 $\mathbf{A} \in \mathbb{R}^{n \times n}$ (n 很大, 无法直接作稠密特征分解), 在 n 维空间中取一个低维子空间 $\mathcal{V}_m = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_m\}$ ($m \ll n$, $\{\mathbf{v}_i\}$ 标准正交, 记 $\mathbf{V}_m = [\mathbf{v}_1, \dots, \mathbf{v}_m]$), 把 $\mathbf{A}$ 限制 (投影) 到 $\mathcal{V}_m$ 上, 用 m 阶小矩阵的特征对去逼近 $\mathbf{A}$ 的特征对:

$$\text{求 } (\theta, \mathbf{y}) \neq \mathbf{0}: \quad \mathbf{V}_m^* (\mathbf{A} \mathbf{V}_m \mathbf{y} - \theta \mathbf{V}_m \mathbf{y}) = \mathbf{0} \iff \mathbf{H}_m \mathbf{y} = \theta \mathbf{y}, \quad \mathbf{H}_m := \mathbf{V}_m^* \mathbf{A} \mathbf{V}_m.$$

θ 称为 Ritz 值, $\mathbf{x} = \mathbf{V}_m \mathbf{y}$ 称为 Ritz 向量. 记残量 $\mathbf{r} = \mathbf{A} \mathbf{x} - \theta \mathbf{x}$. 由投影特征方程 $\mathbf{V}_m^T \mathbf{A} \mathbf{V}_m \mathbf{y} = \theta \mathbf{y}$ 立即得到

$$\mathbf{V}_m^T \mathbf{r} = \mathbf{V}_m^T (\mathbf{A} \mathbf{V}_m \mathbf{y} - \theta \mathbf{V}_m \mathbf{y}) = (\mathbf{V}_m^T \mathbf{A} \mathbf{V}_m - \theta \mathbf{I}) \mathbf{y} = \mathbf{0},$$

即正确的最优性表述是 $\mathbf{r} \perp \mathcal{V}_m$, 这是一种 Galerkin 投影条件 (残量与整个搜索子空间正交), 而不是对固定 θ 在 $\mathcal{V}_m$ 中极小化残量范数 $\|(\mathbf{A} - \theta \mathbf{I}) \mathbf{V}_m \mathbf{z}\|_2$. 事实上, 若固定 θ 并真正关于 $\mathbf{z}$ 极小化该残量范数, 则对应最小二乘问题的正规方程为

$$\mathbf{V}_m^T (\mathbf{A} - \theta \mathbf{I})^T (\mathbf{A} - \theta \mathbf{I}) \mathbf{V}_m \mathbf{z} = \mathbf{0},$$

它与上述投影特征方程一般并不等价. 当 $\mathbf{A}$ 为 Hermite 矩阵时, Rayleigh–Ritz 方法还可以从 Rayleigh 商 $\rho(\mathbf{x}) = \mathbf{x}^T \mathbf{A} \mathbf{x} / \mathbf{x}^T \mathbf{x}$ 的驻点与极值性质来理解. “加速” 的含义: 通过不断扩充 (加速) 低维子空间, 使 Ritz 对迅速逼近 $\mathbf{A}$ 的极端特征对 — 具体做法有: 用残量方向扩充子空间 (精化/重启), 隐式重启 (IRAM, ARPACK), 用位移-反迭代或 Chebyshev 多项式过滤后的向量扩充子空间 (即 “加速” 子空间的收敛) 等.

Rayleigh–Ritz 过程.

1. 取子空间 $\mathcal{V}_m$ 的一组标准正交基 $\mathbf{V}_m = [\mathbf{v}_1, \dots, \mathbf{v}_m]$;
2. 计算投影矩阵 $\mathbf{H}_m = \mathbf{V}_m^* \mathbf{A} \mathbf{V}_m$ ($m \times m$ 矩阵);
3. 解 m 阶特征问题 $\mathbf{H}_m \mathbf{y}_i = \theta_i \mathbf{y}_i, i = 1, \dots, m$;
4. 令 Ritz 向量 $\mathbf{x}_i = \mathbf{V}_m \mathbf{y}_i$, 则 $(\theta_i, \mathbf{x}_i)$ 是 $\mathbf{A}$ 的近似特征对;
5. 用残量 $\mathbf{r}_i = \mathbf{A} \mathbf{x}_i - \theta_i \mathbf{x}_i$ 判定是否收敛; 否则用 $\mathbf{r}_i$ (或过滤后的向量) 扩充子空间, 返回第 1 步.

注 ($\mathbf{H}_m$ 何时为 Hermitian 阵). 当 $\mathbf{A}$ 为一般 (非对称) 矩阵时, $\mathbf{H}_m = \mathbf{V}_m^* \mathbf{A} \mathbf{V}_m$ 通常只是 $m \times m$ 的一般矩阵, 不能无条件称它为 Hermitian 阵; 在 Arnoldi 方法中, 由于 Krylov 子空间的特殊结构, 它表现为上 Hessenberg 阵. 只有当 $\mathbf{A} = \mathbf{A}^*$ 时才有

$$\mathbf{H}_m^* = (\mathbf{V}_m^* \mathbf{A} \mathbf{V}_m)^* = \mathbf{V}_m^* \mathbf{A} \mathbf{V}_m = \mathbf{H}_m,$$

即 $\mathbf{H}_m$ 为 Hermitian 阵 (此时 Ritz 值全为实数, 并有 Rayleigh 商的极值性质).

基本 Arnoldi 算法 (用 MGS 构造 Krylov 子空间的标准正交基). 给定 $\mathbf{v}_1$ ($\|\mathbf{v}_1\|_2 = 1$), 对 $j = 1, 2, \dots, m$:

```

 $\mathbf{w} := \mathbf{A}\mathbf{v}_j;$ 
for  $i = 1 : j$ 
     $h_{ij} := \mathbf{v}_i^* \mathbf{w}; \quad \mathbf{w} := \mathbf{w} - h_{ij} \mathbf{v}_i;$ 
end
 $h_{j+1,j} := \|\mathbf{w}\|_2;$ 
if  $h_{j+1,j} = 0$  then 停止 (已找到不变子空间);
 $\mathbf{v}_{j+1} := \mathbf{w} / h_{j+1,j}.$ 

```

由此得到 Arnoldi 关系

$$\mathbf{A}\mathbf{V}_m = \mathbf{V}_m \mathbf{H}_m + h_{m+1,m} \mathbf{v}_{m+1} \mathbf{e}_m^* = \mathbf{V}_{m+1} \bar{\mathbf{H}}_m, \quad \mathbf{H}_m = \mathbf{V}_m^* \mathbf{A} \mathbf{V}_m \text{ (上 Hessenberg 阵)},$$

其中 $\bar{\mathbf{H}}_m$ 是把 $\mathbf{H}_m$ 添上第 $m+1$ 行 $(0, \dots, 0, h_{m+1,m})$ 得到的 $(m+1) \times m$ 阵.

于是对 $\mathbf{H}_m$ 作 Rayleigh-Ritz 过程即得 $\mathbf{A}$ 的近似特征对; 若 $(\theta_i, \mathbf{y}_i)$ 是 $\mathbf{H}_m$ 的特征对, 则

$$\|\mathbf{A}\mathbf{x}_i - \theta_i \mathbf{x}_i\|_2 = \|(\mathbf{A}\mathbf{V}_m - \mathbf{V}_m \mathbf{H}_m) \mathbf{y}_i\|_2 = h_{m+1,m} |\mathbf{e}_m^* \mathbf{y}_i|,$$

它提供了一个廉价的收敛判据: $h_{m+1,m} |\mathbf{e}_m^* \mathbf{y}_i|$ 足够小时 $(\theta_i, \mathbf{x}_i)$ 即为收敛的近似特征对.

2 解线性方程组的迭代法

以下均取 $\mathbf{A} = \begin{pmatrix} 6 & 3 \\ 3 & 2 \end{pmatrix}$ (对称正定: 顺序主子式 $6 > 0$, $\det \mathbf{A} = 3 > 0$), $\mathbf{b} = \begin{pmatrix} 0 \\ -1 \end{pmatrix}$, 方程组 $\mathbf{A}\mathbf{x} = \mathbf{b}$ 的精确解为

$$\mathbf{x}^* = \mathbf{A}^{-1} \mathbf{b} = \frac{1}{3} \begin{pmatrix} 2 & -3 \\ -3 & 6 \end{pmatrix} \begin{pmatrix} 0 \\ -1 \end{pmatrix} = \begin{pmatrix} 1 \\ -2 \end{pmatrix}.$$

($\mathbf{A}$ 的特征值为 $\lambda_{1,2} = 4 \pm \sqrt{13}$, 即 $\lambda_{\min} = 0.3944487$, $\lambda_{\max} = 7.6055513$, 条件数 $\kappa_2(\mathbf{A}) = \lambda_{\max}/\lambda_{\min} = 19.28147$.)

1. $\mathbf{A}$ -椭圆范数

对 $\mathbf{x} = (1, 1)^T$,

$$\mathbf{A}\mathbf{x} = \begin{pmatrix} 6 \cdot 1 + 3 \cdot 1 \\ 3 \cdot 1 + 2 \cdot 1 \end{pmatrix} = \begin{pmatrix} 9 \\ 5 \end{pmatrix}, \quad \|\mathbf{x}\|_{\mathbf{A}} = \sqrt{\mathbf{x}^T \mathbf{A} \mathbf{x}} = \sqrt{9 + 5} = \sqrt{14}.$$

即 $\|\mathbf{x}\|_{\mathbf{A}} = \sqrt{14} \approx 3.7417$. 严格来说, 只有当 $\mathbf{A}$ 是对称正定矩阵时, $\|\cdot\|_{\mathbf{A}} = \sqrt{\mathbf{x}^T \mathbf{A} \mathbf{x}}$ 才是一个范数 (正定性与三角不等式都要用到 $\mathbf{A}$ 的对称正定性); 本题的 $\mathbf{A}$ 满足这一要求.

2. SD 与 CG 的迭代公式及求解

SD (最速下降法). 给定 $\mathbf{x}^{(0)}$, 对 $k = 0, 1, 2, \dots$

$$\mathbf{r}^{(k)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(k)}, \quad \alpha_k = \frac{\langle \mathbf{r}^{(k)}, \mathbf{r}^{(k)} \rangle}{\langle \mathbf{r}^{(k)}, \mathbf{A}\mathbf{r}^{(k)} \rangle}, \quad \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{r}^{(k)}.$$

($\mathbf{r}^{(k)} = -\nabla E(\mathbf{x}^{(k)})$, $E(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T \mathbf{A}\mathbf{x} - \mathbf{b}^T \mathbf{x}$, α_k 是沿 $\mathbf{r}^{(k)}$ 作精确一维极小化的步长.)

CG (共轭梯度法). 给定 $\mathbf{x}^{(0)}$, 令 $\mathbf{r}^{(0)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(0)}$, $\mathbf{p}^{(0)} = \mathbf{r}^{(0)}$, 对 $k = 0, 1, 2, \dots$

$$\alpha_k = \frac{\langle \mathbf{r}^{(k)}, \mathbf{r}^{(k)} \rangle}{\langle \mathbf{p}^{(k)}, \mathbf{A}\mathbf{p}^{(k)} \rangle}, \quad \mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{p}^{(k)},$$

$$\mathbf{r}^{(k+1)} = \mathbf{r}^{(k)} - \alpha_k \mathbf{A}\mathbf{p}^{(k)}, \quad \beta_k = \frac{\langle \mathbf{r}^{(k+1)}, \mathbf{r}^{(k+1)} \rangle}{\langle \mathbf{r}^{(k)}, \mathbf{r}^{(k)} \rangle}, \quad \mathbf{p}^{(k+1)} = \mathbf{r}^{(k+1)} + \beta_k \mathbf{p}^{(k)}.$$

取 $\mathbf{x}^{(0)} = (0, 0)^T$ 求解.

SD 的计算:

$$\begin{aligned} \mathbf{r}^{(0)} &= \begin{pmatrix} 0 \\ -1 \end{pmatrix}, \quad \alpha_0 = \frac{1}{2}, \quad \mathbf{x}^{(1)} = \begin{pmatrix} 0 \\ -\frac{1}{2} \end{pmatrix}; \\ \mathbf{r}^{(1)} &= \begin{pmatrix} \frac{3}{2} \\ 0 \end{pmatrix}, \quad \alpha_1 = \frac{9/4}{27/2} = \frac{1}{6}, \quad \mathbf{x}^{(2)} = \begin{pmatrix} \frac{1}{4} \\ -\frac{1}{2} \end{pmatrix}; \\ \mathbf{r}^{(2)} &= \begin{pmatrix} 0 \\ \frac{3}{4} \end{pmatrix}, \quad \alpha_2 = \frac{1}{2}, \quad \mathbf{x}^{(3)} = \begin{pmatrix} \frac{1}{4} \\ -\frac{7}{8} \end{pmatrix}; \\ \mathbf{r}^{(3)} &= \begin{pmatrix} \frac{9}{8} \\ 0 \end{pmatrix}, \quad \alpha_3 = \frac{1}{6}, \quad \mathbf{x}^{(4)} = \begin{pmatrix} \frac{7}{16} \\ -\frac{7}{8} \end{pmatrix}; \dots \end{aligned}$$

一般地

$$\mathbf{x}^{(2j)} = \begin{pmatrix} 1 - \left(\frac{3}{4}\right)^j \\ -2 + 2\left(\frac{3}{4}\right)^j \end{pmatrix}, \quad \mathbf{x}^{(2j+1)} = \begin{pmatrix} 1 - \left(\frac{3}{4}\right)^{j+1} \\ -2 + 2\left(\frac{3}{4}\right)^{j+1} \end{pmatrix}, \quad j = 0, 1, 2, \dots$$

残量在两个坐标轴方向交替出现 ($\mathbf{r}^{(2j)} \parallel \mathbf{e}_2$, $\mathbf{r}^{(2j+1)} \parallel \mathbf{e}_1$), 迭代点呈“之”字形趋于 $\mathbf{x}^* = (1, -2)^T$, 误差每两步缩小为原来的 $\frac{3}{4}$, 即线性收敛.

CG 的计算:

$$\begin{aligned} \mathbf{r}^{(0)} &= \mathbf{p}^{(0)} = \begin{pmatrix} 0 \\ -1 \end{pmatrix}, \quad \alpha_0 = \frac{1}{\langle \mathbf{p}^{(0)}, \mathbf{A}\mathbf{p}^{(0)} \rangle} = \frac{1}{2}, \quad \mathbf{x}^{(1)} = \begin{pmatrix} 0 \\ -\frac{1}{2} \end{pmatrix}; \\ \mathbf{r}^{(1)} &= \begin{pmatrix} \frac{3}{2} \\ 0 \end{pmatrix}, \quad \beta_0 = \frac{9/4}{1} = \frac{9}{4}, \quad \mathbf{p}^{(1)} = \mathbf{r}^{(1)} + \frac{9}{4}\mathbf{p}^{(0)} = \begin{pmatrix} \frac{3}{2} \\ \frac{9}{4} \end{pmatrix}; \\ \langle \mathbf{p}^{(1)}, \mathbf{A}\mathbf{p}^{(1)} \rangle &= \frac{27}{8}, \quad \alpha_1 = \frac{9/4}{27/8} = \frac{2}{3}, \quad \mathbf{x}^{(2)} = \mathbf{x}^{(1)} + \frac{2}{3}\mathbf{p}^{(1)} = \begin{pmatrix} 1 \\ -2 \end{pmatrix} = \mathbf{x}^*, \end{aligned}$$

此时 $\mathbf{r}^{(2)} = \mathbf{0}$, 迭代终止. CG 对 $n \times n$ 的对称正定线性系统在精确算术下至多经 n 步得到精确解; 本题 $n = 2$, 故 CG 至多经 2 步即得精确解 (事实上第 1 步与 SD 相同, 第 2 步到达 $\mathbf{x}^*$). 应注意这与由条件数得到的一般收敛上界 (见第 4 题) 不是同一个概念.

3. 两种方法的几何解释

能量泛函 $E(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{b}^T \mathbf{x}$ 的等值线是以 $\mathbf{x}^*$ 为中心的一族同心椭圆, 其长短轴方向就是 $\mathbf{A}$ 的特征向量方向, 半轴长度之比为 $\sqrt{\lambda_{\max}/\lambda_{\min}} = \sqrt{\kappa_2(\mathbf{A})}$.

SD 的几何意义. 每一步沿当前点的负梯度方向 $\mathbf{r}^{(k)}$ (即与过该点的等值线垂直的方向) 作精确一维极小化, 即沿该方向走到与椭圆相切处. 记搜索方向 $\mathbf{p}_k = \mathbf{r}^{(k)}$, 则由精确线搜索的一阶最优条件

$$\langle \mathbf{r}^{(k+1)}, \mathbf{r}^{(k)} \rangle = 0 \implies \mathbf{p}_{k+1} \perp \mathbf{p}_k,$$

即相邻两次搜索方向严格正交, 而不是“几乎相反”; 迭代点因此在目标点两侧来回摆动, 路径呈“之”字形 (zigzag) 逼近椭圆中心. 当 $\kappa_2(\mathbf{A}) = \lambda_{\max}/\lambda_{\min} \gg 1$ 时, 二次函数的等高线非常狭长 (呈狭长谷底状), SD 容易在谷底两侧交替前进: 每一步只沿当前等值线的法向走到与该等值线相切, 再沿新的法向折回, 每次前进沿谷底方向的分量都很小, 从而形成明显的 zig-zag 现象, 收敛速度很慢. 因此收敛缓慢的原因不是相邻方向“几乎相反”, 而是问题的病态性导致迭代轨迹出现剧烈的之字形运动. 本题中 $\mathbf{x}^{(0)} = \mathbf{0}$, $\mathbf{r}^{(0)} = (0, -1)^T$ 是竖直方向, 走到椭圆 (此处为椭圆) 的切点 $\mathbf{x}^{(1)} = (0, -\frac{1}{2})^T$; 随后 $\mathbf{r}^{(1)} = (\frac{3}{2}, 0)^T$ 是水平方向, 走到 $\mathbf{x}^{(2)} = (\frac{1}{4}, -\frac{1}{2})^T$; 如此在竖直, 水平两个方向间交替, 形成“阶梯形”路径. 并且 $(\mathbf{r}^{(0)})^T \mathbf{r}^{(1)} = 0 \cdot \frac{3}{2} + (-1) \cdot 0 = 0$, 直接验证了相邻两次搜索方向严格正交这一结论.

CG 的几何意义. CG 的第 k 步在仿射子空间 $\mathbf{x}^{(0)} + \mathcal{K}_k(\mathbf{A}, \mathbf{r}^{(0)})$ 上取 $\mathbf{A}$ -范数 (能量范数) 意义下的最优近似, 等价地满足 Galerkin 条件 $\mathbf{r}^{(k)} \perp \mathcal{K}_k(\mathbf{A}, \mathbf{r}^{(0)})$ (见第 6 题). 其搜索方向 $\mathbf{p}^{(0)}, \mathbf{p}^{(1)}, \dots$ 关于 $\mathbf{A}$ 共轭 ($\mathbf{A}$ -正交): $\langle \mathbf{p}^{(i)}, \mathbf{A} \mathbf{p}^{(j)} \rangle = 0$ ($i \neq j$), 几何上就是沿椭圆的一族共轭直径方向前进, 每步都在一个新的“方向”上取到该椭圆的极小点, 不重复以前走过的方向, 因此不会像 SD 那样在两条几乎相同的方向间反复拉锯; 在 n 维空间中至多 n 步即可到达椭圆中心 $\mathbf{x}^*$. 本题 $\mathbf{p}^{(0)} = (0, -1)^T$ (竖直), $\mathbf{p}^{(1)} = (\frac{3}{2}, -\frac{9}{4})^T$, 且 $\langle \mathbf{p}^{(1)}, \mathbf{A} \mathbf{p}^{(0)} \rangle = 0$ (共轭), 两步即到达中心.

4. 达到 10^{-8} 精度所需迭代步数的估计 (2-范数)

取 $\mathbf{x}^{(0)} = \mathbf{0}$, 则误差 $\mathbf{e}^{(k)} = \mathbf{x}^{(k)} - \mathbf{x}^*$ 满足

$$\|\mathbf{e}^{(0)}\|_2 = \sqrt{5} \approx 2.236068, \quad \|\mathbf{e}^{(0)}\|_{\mathbf{A}} = \sqrt{\mathbf{b}^T \mathbf{A}^{-1} \mathbf{b}} = \sqrt{(\mathbf{x}^*)^T \mathbf{b}} = \sqrt{2} \approx 1.414214.$$

(用 $\|\mathbf{e}\|_2 \leq \|\mathbf{e}\|_{\mathbf{A}} / \sqrt{\lambda_{\min}}$, $\sqrt{\lambda_{\min}} = 0.6280525$, 把能量范数估计换算为 2-范数.)

SD 的估计. 标准误差估计为

$$\|\mathbf{e}^{(k)}\|_{\mathbf{A}} \leq \left(\frac{\kappa - 1}{\kappa + 1} \right)^k \|\mathbf{e}^{(0)}\|_{\mathbf{A}}, \quad \frac{\kappa - 1}{\kappa + 1} = \frac{18.28147}{20.28147} = 0.9013878 \quad (\kappa = 19.28147).$$

要求 $\|\mathbf{e}^{(k)}\|_2 \leq 10^{-8}$, 只需 $0.9013878^k \cdot \frac{1.414214}{0.6280525} \leq 10^{-8}$, 即 $0.9013878^k \leq 4.441 \times 10^{-9}$,

$$k \geq \frac{\ln(4.441 \times 10^{-9})}{\ln 0.9013878} = \frac{-19.2324}{-0.103854} \approx 185.2 \implies k \approx 186 \text{ 步}.$$

(对本例还可精确算出 $\mathbf{e}^{(2j)} = (-(3/4)^j, 2(3/4)^j)^T$, $\|\mathbf{e}^{(2j)}\|_2 = \sqrt{5} (3/4)^j$, 于是实际只需 $j \geq 67$, 即 $k \approx 134$ 步 — 真实收敛比上面的上界估计更快.)

CG 的估计. 标准误差估计为

$$\|\mathbf{e}^{(k)}\|_{\mathbf{A}} \leq 2 \left(\frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} \right)^k \|\mathbf{e}^{(0)}\|_{\mathbf{A}}, \quad \frac{\sqrt{\kappa} - 1}{\sqrt{\kappa} + 1} = \frac{4.39107 - 1}{4.39107 + 1} = 0.6290159.$$

要求 $\|e^{(k)}\|_2 \leq 10^{-8}$, 只需 $2 \cdot 0.6290159^k \cdot \frac{1.414214}{0.6280525} \leq 10^{-8}$, 即 $0.6290159^k \leq 2.221 \times 10^{-9}$,

$$k \geq \frac{\ln(2.221 \times 10^{-9})}{\ln 0.6290159} = \frac{-19.9258}{-0.463554} \approx 43.0 \implies k \approx 43 \text{ 步}.$$

(实际上 $n = 2$, CG 在精确算术下 2 步即精确收敛, 数值计算中约 2 ~ 3 步即可达到机器精度; 上面的 43 步是把 CG 当作一般 n 阶问题得到的上界估计.)

结论. 按 2-范数误差 10^{-8} 估计: SD 约需 186 步 (本例实际约 134 步), CG 的估计上界约 43 步 (本例实际 2 步). 需要强调: 由条件数得到的是理论上保守的估计, 而不是该具体问题的实际迭代次数; 对本题的二维对称正定系统, 精确算术下 CG 满足 $k \leq 2$, 不能把 43 步理解为本例实际所需的步数. 可见 CG 远优于 SD, 这正是 Krylov 子空间方法的价值所在.

5. SD 的最后一个非零残量是 A 的特征向量

设 SD 迭代为

$$r^{(k)} = b - Ax^{(k)}, \quad x^{(k+1)} = x^{(k)} + \alpha_k r^{(k)}, \quad \alpha_k = \frac{\langle r^{(k)}, r^{(k)} \rangle}{\langle r^{(k)}, Ar^{(k)} \rangle} \neq 0,$$

故残量满足

$$r^{(k+1)} = r^{(k)} - \alpha_k Ar^{(k)}. \quad (*)$$

设迭代在第 k 步终止, 即 $r^{(k)} = 0$ 而 $r^{(k-1)} \neq 0$ (即 $r^{(k-1)}$ 是“最后一个非零残量”). 在 (*) 中取指标 $k-1$:

$$0 = r^{(k)} = r^{(k-1)} - \alpha_{k-1} Ar^{(k-1)} \implies Ar^{(k-1)} = \frac{1}{\alpha_{k-1}} r^{(k-1)}.$$

即 $r^{(k-1)}$ 是 A 的特征向量, 对应的特征值为 $\lambda = 1/\alpha_{k-1}$. $\square$

逆命题 (有限步终止的充要条件). 设 $r^{(k-1)} \neq 0$ 是 A 的特征向量, $Ar^{(k-1)} = \lambda r^{(k-1)}$, 则

$$\alpha_{k-1} = \frac{\langle r^{(k-1)}, r^{(k-1)} \rangle}{\langle r^{(k-1)}, Ar^{(k-1)} \rangle} = \frac{1}{\lambda}, \quad r^{(k)} = r^{(k-1)} - \frac{1}{\lambda} \cdot \lambda r^{(k-1)} = 0,$$

即下一步立刻终止于精确解 $x^{(k)} = x^*$. 因此: SD 有限步终止 $\iff$ 某个残量恰为 A 的特征向量 (即残量落入 A 的一维不变子空间), 而终止前的最后一个非零残量正是这个特征向量.

注. 一般情形下 (初值任意, A 无重特征值), SD 不会有限步终止, 残量只满足 $\|r^{(k)}\|_2 \rightarrow 0$ 而永不为零: 例如第 2 题中 $r^{(2j)} = (0, -3 \cdot (3/4)^{j-1}/4)^T$, $r^{(2j+1)} = (9 \cdot (3/4)^{j-1}/8, 0)^T$, 都趋于 0 但不等于 0, 而它们都平行于坐标轴方向, 并不是 A 的特征向量方向 (A 的特征向量方向由 $\lambda_{1,2} = 4 \pm \sqrt{13}$ 决定).

6. A^{-1} -范数残量极小化与残量正交化条件的等价性

设 A 对称正定, $\mathcal{K} = \mathcal{K}_k(A, b)$ (k 维子空间), $x^{(k)} \in \mathcal{K}$. 要证

$$\|r^{(k)}\|_{A^{-1}} = \|b - Ax^{(k)}\|_{A^{-1}} = \min_{x \in \mathcal{K}} \|b - Ax\|_{A^{-1}} \iff \langle z, r^{(k)} \rangle = z^T (b - Ax^{(k)}) = 0, \quad \forall z \in \mathcal{K}.$$

(这里 $\|r\|_{A^{-1}}^2 = r^T A^{-1} r$, 即题中 $\|r\|_{(A^{-1})^{-1/2}}^2$; 注意它恰好就是残量的能量范数: $\|b - Ax\|_{A^{-1}}^2 = 2E(x) + b^T A^{-1} b$.) 作为直观理解, 由 $b - Ax = A(x^* - x)$ 可得

$$\|b - Ax\|_{A^{-1}}^2 = (b - Ax)^T A^{-1} (b - Ax) = (x^* - x)^T A (x^* - x) = \|x^* - x\|_A^2,$$

即极小化 $\mathbf{A}^{-1}$ -范数残量等价于极小化 $\mathbf{A}$ -范数误差, 这正是 CG 的能量范数最优性的来源.

证明. 记 $\mathbf{r} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(k)}$. 由于 $\mathbf{A}$ 对称正定, $\mathbf{A}^{1/2}$ 存在且非奇异, 于是

$$\|\mathbf{b} - \mathbf{A}\mathbf{x}\|_{\mathbf{A}^{-1}}^2 = (\mathbf{b} - \mathbf{A}\mathbf{x})^T \mathbf{A}^{-1} (\mathbf{b} - \mathbf{A}\mathbf{x}) = \|\mathbf{A}^{1/2}\mathbf{x} - \mathbf{A}^{-1/2}\mathbf{b}\|_2^2,$$

即原问题等价于一个线性最小二乘问题: $\min_{\mathbf{x} \in \mathcal{K}} \|\mathbf{A}^{1/2}\mathbf{x} - \mathbf{A}^{-1/2}\mathbf{b}\|_2$. 由于 $\mathbf{A}^{1/2}$ 非奇异, 它在子空间 $\mathcal{K}$ 上的限制是单射, 故该最小二乘问题有唯一解, 且由法方程刻画.

(必要性) 若 $\mathbf{x}^{(k)}$ 是极小点, 则对任意 $\mathbf{z} \in \mathcal{K}$ 及任意 $t \in \mathbb{R}$, $\mathbf{x}^{(k)} + t\mathbf{z} \in \mathcal{K}$, 由

$$0 = \frac{d}{dt} \|\mathbf{b} - \mathbf{A}(\mathbf{x}^{(k)} + t\mathbf{z})\|_{\mathbf{A}^{-1}}^2 \Big|_{t=0} = -2\mathbf{z}^T (\mathbf{b} - \mathbf{A}\mathbf{x}^{(k)}) = -2\langle \mathbf{z}, \mathbf{r} \rangle$$

得 $\langle \mathbf{z}, \mathbf{r} \rangle = 0$ 对一切 $\mathbf{z} \in \mathcal{K}$ 成立.

(充分性) 设 $\langle \mathbf{z}, \mathbf{r} \rangle = 0$ ($\forall \mathbf{z} \in \mathcal{K}$). 对任意 $\mathbf{y} \in \mathcal{K}$, $(\mathbf{x}^{(k)} - \mathbf{y}) \in \mathcal{K}$, 于是

$$\|\mathbf{b} - \mathbf{A}\mathbf{y}\|_{\mathbf{A}^{-1}}^2 = \|\mathbf{r} + \mathbf{A}(\mathbf{x}^{(k)} - \mathbf{y})\|_{\mathbf{A}^{-1}}^2 = \|\mathbf{r}\|_{\mathbf{A}^{-1}}^2 + 2 \underbrace{\langle \mathbf{x}^{(k)} - \mathbf{y}, \mathbf{r} \rangle}_{=0} + \|\mathbf{x}^{(k)} - \mathbf{y}\|_{\mathbf{A}}^2 \geq \|\mathbf{r}\|_{\mathbf{A}^{-1}}^2,$$

即 $\mathbf{x}^{(k)}$ 为极小点. $\square$

注. 充分性证明中用到 $\|\mathbf{A}\mathbf{v}\|_{\mathbf{A}^{-1}}^2 = \mathbf{v}^T \mathbf{A} \mathbf{v} = \|\mathbf{v}\|_{\mathbf{A}}^2$. 该结论说明: 在 Krylov 子空间中极小化 $\mathbf{A}^{-1}$ -范数 (能量范数) 残量与要求残量与整个搜索子空间正交 (Galerkin 条件) 是同一件事, 这正是 CG 方法的基本特征 (CG 的 $\mathbf{x}^{(k)}$ 正是该极小化问题的解).

7. CG 迭代点列使能量函数单调不增

按题设

$$E(\mathbf{x}) = \frac{1}{2} \|\mathbf{A}\mathbf{x} - \mathbf{b}\|_{(\mathbf{A}^{-1})^{-1/2}}^2 = \frac{1}{2} (\mathbf{A}\mathbf{x} - \mathbf{b})^T \mathbf{A}^{-1} (\mathbf{A}\mathbf{x} - \mathbf{b}) = \frac{1}{2} \mathbf{x}^T \mathbf{A} \mathbf{x} - \mathbf{b}^T \mathbf{x} + \frac{1}{2} \mathbf{b}^T \mathbf{A}^{-1} \mathbf{b}.$$

证明 (用精确线搜索). CG 的迭代为 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha \mathbf{p}^{(k)}$, 其中 $\alpha = \alpha_k = \frac{\langle \mathbf{r}^{(k)}, \mathbf{r}^{(k)} \rangle}{\langle \mathbf{p}^{(k)}, \mathbf{A}\mathbf{p}^{(k)} \rangle}$, $\mathbf{r}^{(k)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(k)}$, 且 $\langle \mathbf{r}^{(k)}, \mathbf{p}^{(k)} \rangle = \langle \mathbf{r}^{(k)}, \mathbf{r}^{(k)} \rangle > 0$. 于是

$$E(\mathbf{x}^{(k)} + \alpha \mathbf{p}^{(k)}) = E(\mathbf{x}^{(k)}) - \alpha \langle \mathbf{r}^{(k)}, \mathbf{p}^{(k)} \rangle + \frac{\alpha^2}{2} \|\mathbf{p}^{(k)}\|_{\mathbf{A}}^2 = E(\mathbf{x}^{(k)}) - \alpha \langle \mathbf{r}^{(k)}, \mathbf{r}^{(k)} \rangle + \frac{\alpha^2}{2} \langle \mathbf{p}^{(k)}, \mathbf{A}\mathbf{p}^{(k)} \rangle.$$

这是关于 α 的开口向上的二次函数, 在 $\alpha = \alpha_k = \langle \mathbf{r}^{(k)}, \mathbf{r}^{(k)} \rangle / \langle \mathbf{p}^{(k)}, \mathbf{A}\mathbf{p}^{(k)} \rangle$ 处取最小值, 最小值为

$$E(\mathbf{x}^{(k+1)}) = E(\mathbf{x}^{(k)}) - \frac{1}{2} \frac{\langle \mathbf{r}^{(k)}, \mathbf{r}^{(k)} \rangle^2}{\langle \mathbf{p}^{(k)}, \mathbf{A}\mathbf{p}^{(k)} \rangle} \leq E(\mathbf{x}^{(k)}).$$

即 $E(\mathbf{x}^{(k+1)}) \leq E(\mathbf{x}^{(k)})$, 单调不增.

严格性. 若 $\mathbf{r}^{(k)} \neq \mathbf{0}$, 则 $\langle \mathbf{r}^{(k)}, \mathbf{r}^{(k)} \rangle > 0$; 又 $\mathbf{p}^{(k)} \neq \mathbf{0}$ (在 $\mathbf{r}^{(k)} \neq \mathbf{0}$ 之前 CG 不会中断) 且 $\mathbf{A}$ 正定, 故 $\langle \mathbf{p}^{(k)}, \mathbf{A}\mathbf{p}^{(k)} \rangle > 0$, 于是上面的减量严格大于零:

$$E(\mathbf{x}^{(k+1)}) < E(\mathbf{x}^{(k)}) \quad (\mathbf{r}^{(k)} \neq \mathbf{0}). \quad \square$$

另证 (用投影观点). CG 的 $\mathbf{x}^{(k)}$ 是 $\min_{\mathbf{x} \in \mathbf{x}^{(0)} + \mathcal{K}_k(\mathbf{A}, \mathbf{r}^{(0)})} E(\mathbf{x})$ 的解 (第 6 题), 而 $\mathcal{K}_k \subset \mathcal{K}_{k+1}$, 故 $E(\mathbf{x}^{(k+1)}) \leq E(\mathbf{x}^{(k)})$. 严格性: 当 $\mathbf{r}^{(k)} \neq \mathbf{0}$ 时 $\mathbf{r}^{(k)} \in \mathcal{K}_{k+1}(\mathbf{A}, \mathbf{r}^{(0)})$, 对小的 $t > 0$, $\mathbf{x}^{(k)} + t\mathbf{r}^{(k)} \in \mathbf{x}^{(0)} + \mathcal{K}_{k+1}$ 且

$$E(\mathbf{x}^{(k)} + t\mathbf{r}^{(k)}) = E(\mathbf{x}^{(k)}) - t \|\mathbf{r}^{(k)}\|_2^2 + \frac{t^2}{2} \|\mathbf{r}^{(k)}\|_{\mathbf{A}}^2 < E(\mathbf{x}^{(k)}),$$

故 $\mathcal{K}_{k+1}$ 上的极小值严格小于 $\mathcal{K}_k$ 上的极小值, 即 $E(\mathbf{x}^{(k+1)}) < E(\mathbf{x}^{(k)})$. $\square$

8. MINRES 与 GMRES 的思想与步骤

GMRES (Generalized Minimal Residual, 广义极小残量法) — 适用于一般 (非对称) 矩阵. 思想: 在仿射 Krylov 子空间 $\mathbf{x}^{(0)} + \mathcal{K}_k(\mathbf{A}, \mathbf{r}^{(0)})$ 中, 使残量的 2-范数达到极小:

$$\mathbf{x}^{(k)} = \arg \min_{\mathbf{x} \in \mathbf{x}^{(0)} + \mathcal{K}_k(\mathbf{A}, \mathbf{r}^{(0)})} \|\mathbf{b} - \mathbf{A}\mathbf{x}\|_2.$$

步骤:

1. 计算 $\mathbf{r}^{(0)} = \mathbf{b} - \mathbf{A}\mathbf{x}^{(0)}$, $\beta = \|\mathbf{r}^{(0)}\|_2$, $\mathbf{v}_1 = \mathbf{r}^{(0)}/\beta$;
2. 用 Arnoldi 过程逐步构造 $\mathcal{K}_k$ 的标准正交基 $\mathbf{V}_k = [\mathbf{v}_1, \dots, \mathbf{v}_k]$ 与上 Hessenberg 阵 $\bar{\mathbf{H}}_k \in \mathbb{R}^{(k+1) \times k}$, 满足 $\mathbf{A}\mathbf{V}_k = \mathbf{V}_{k+1}\bar{\mathbf{H}}_k$, 从而 $\mathbf{x} = \mathbf{x}^{(0)} + \mathbf{V}_k\mathbf{y}$ 时 $\|\mathbf{b} - \mathbf{A}\mathbf{x}\|_2 = \|\beta\mathbf{e}_1 - \bar{\mathbf{H}}_k\mathbf{y}\|_2$;
3. 用 Givens 旋转变换把 $\bar{\mathbf{H}}_k$ 逐步化为上三角形 (每加入一列只需 $O(k)$ 次旋转), 同时更新右端项, 从而以最小二乘意义解出 $\mathbf{y}_k$, 得 $\mathbf{x}^{(k)} = \mathbf{x}^{(0)} + \mathbf{V}_k\mathbf{y}_k$;
4. 第 k 步的残量范数可由旋转后的右端项最后一个分量直接读出 (无需计算 $\mathbf{x}^{(k)}$), 据此判断是否收敛; 若未收敛则 $k \leftarrow k+1$, 返回第 2 步.

特点: 残量范数单调不增; 在精确算术下, GMRES 至多经历 n 个 Krylov 维度后即可达到 Krylov 子空间中的最小残差; 对于存在精确解的非奇异线性系统, 在相应的无提前退化情形下, 至多 n 个维度内即可得到精确解 (即通常所说的“至多 n 步终止”). 但需注意: 若 $\mathbf{A}$ 奇异且方程组 $\mathbf{A}\mathbf{x} = \mathbf{b}$ 不相容, 则可能根本不存在精确解, 此时不能笼统地说“残差在 n 步后为零”, 而只能说达到了 Krylov 子空间内的最小残差; 但基向量需全部存储 (长递推), 存储量与每步运算量都随 k 线性增长, 故实际中常用重启的 GMRES(m) (每 m 步重新开始) 或截断/拟最小残量 (Quasi-Minimal Residual) 等变形.

MINRES (Minimum Residual, 极小残量法) — 适用于对称 (可不定) 矩阵. 思想: 与 GMRES 相同的极小化目标 $\min \|\mathbf{b} - \mathbf{A}\mathbf{x}\|_2$, 但利用 $\mathbf{A}$ 对称 (自伴) 这一事实: 这时 Arnoldi 过程退化为 Lanczos 过程, $\mathbf{H}_k$ 成为对称三对角阵, 基向量满足三项递推, 故可用短递推实现, 存储量只有 $O(n)$; 每步的主要开销是矩阵-向量乘法, 稀疏情形下应写成 $O(\text{nnz}(\mathbf{A}))$, 而不能无条件简化为 $O(n)$, 此外还有 $O(n)$ 的向量运算. 只有当 $\text{nnz}(\mathbf{A}) = O(n)$ 时, 每步运算量才可进一步简化为 $O(n)$ (与 CG 同量级). 步骤:

1. 初始化 $\mathbf{v}_0 = \mathbf{0}$, $\mathbf{v}_1 = \mathbf{r}^{(0)}/\beta$, $\beta = \|\mathbf{r}^{(0)}\|_2$;
2. 对 $k = 1, 2, \dots$ 作 Lanczos 三项递推 $\mathbf{w} = \mathbf{A}\mathbf{v}_k - \beta_k\mathbf{v}_{k-1}$, $\alpha_k = \langle \mathbf{v}_k, \mathbf{w} \rangle$, $\mathbf{w} \leftarrow \mathbf{w} - \alpha_k\mathbf{v}_k$, $\beta_{k+1} = \|\mathbf{w}\|_2$, $\mathbf{v}_{k+1} = \mathbf{w}/\beta_{k+1}$;
3. 以 α_k, β_k 组装三对角阵 $\mathbf{T}_k$ (及其带 $(k+1)$ 行的 $\bar{\mathbf{T}}_k$), 用一串 Givens 旋转逐步把 $\bar{\mathbf{T}}_k$ 化为上三角, 递推求解 $\min \|\beta\mathbf{e}_1 - \bar{\mathbf{T}}_k\mathbf{y}\|_2$;
4. 由三项递推同步更新 $\mathbf{x}^{(k)}$, 并用旋转后的右端项估计残量范数, 判定收敛.

特点: 兼具 CG 的短递推 ($O(n)$ 存储) 与 GMRES 的残量极小性, 且对不定 (甚至奇异) 的对称矩阵也适用; 但不能像 CG 那样利用正定性给出能量范数意义下的误差估计. (对对称正定矩阵, CG 在能量范数下最优, 通常比 MINRES 更有效.)

3 非线性方程组的迭代解法

1. $F' \equiv \mathbf{O}$ 蕴含 F 为常向量值函数

先列出用到的两个事实.

(i) 向量值函数的微分中值不等式. 设 F 在包含线段 $[x, y] = \{x + t(y - x) : 0 \leq t \leq 1\}$ 的开集上 Fréchet 可微, 则

$$\|F(y) - F(x)\|_2 \leq \sup_{0 \leq t \leq 1} \|F'(x + t(y - x))\|_2 \cdot \|y - x\|_2.$$

证明: 令 $g(t) = F(x + t(y - x))$, $t \in [0, 1]$. 则 g 可微且 $g'(t) = F'(x + t(y - x))(y - x)$. 由微积分基本定理与积分范数不等式,

$$\|g(1) - g(0)\|_2 = \left\| \int_0^1 g'(t) dt \right\|_2 \leq \int_0^1 \|g'(t)\|_2 dt \leq \sup_{0 \leq t \leq 1} \|F'(\cdots)\|_2 \|y - x\|_2. \quad \square$$

(ii) 开连通集是折线连通的. 设 $D \subset \mathbb{R}^m$ 是开区域 (即开集且连通), 则对任意 $x, y \in D$, 存在 D 内的折线 $z_0 = x, z_1, \dots, z_N = y$ 连接它们, 且每条线段 $[z_{i-1}, z_i] \subset D$. (这是 $\mathbb{R}^m$ 中开连通集的基本性质: 开集连通 $\Rightarrow$ 道路连通 $\Rightarrow$ 折线连通.)

证明题设结论. 设 $x, y \in D$ 任意, 取 (ii) 中的折线. 对每一段 $[z_{i-1}, z_i]$, 由于 D 上 $F' \equiv O$, 由 (i) 得

$$\|F(z_i) - F(z_{i-1})\|_2 \leq \sup_t \|F'(\cdots)\|_2 \|z_i - z_{i-1}\|_2 = 0,$$

故 $F(z_i) = F(z_{i-1})$. 逐段相加得 $F(x) = F(z_1) = \cdots = F(y)$. 由 x, y 的任意性, F 在 D 上为常向量值函数. $\square$

注. 证明中只用到 D 开且连通 (从而折线连通), “边界光滑”并非必要; 若 D 不连通, 则 F 在每个连通分支上为常值, 整体不必为常值.

2. 二分法求 $f(x) = x^2 - 4$ 在 $[1, 3]$ 中的根

算法. 设 $f \in C[a, b]$, $f(a)f(b) < 0$: 取 $a_0 = a, b_0 = b$, 对 $k = 1, 2, \dots$

$$x_k = \frac{a_{k-1} + b_{k-1}}{2}; \quad \text{若 } f(a_{k-1})f(x_k) < 0 \text{ 则 } (a_k, b_k) = (a_{k-1}, x_k), \text{ 否则 } (a_k, b_k) = (x_k, b_{k-1});$$

若 $f(x_k) = 0$ 则停止, x_k 即为根.

前三步迭代过程. $f(1) = -3 < 0, f(3) = 5 > 0$.

$$k = 1: [a_0, b_0] = [1, 3], \quad x_1 = \frac{1+3}{2} = 2, \quad f(2) = 0 \Rightarrow \text{已得精确根 } x = 2;$$

按标准二分法算法, 此时应立即停止, 故正确的结论是 $x_1 = 2$ 且算法在第一次迭代后终止. 若为了展示区间缩减过程而假设不立即停止, 继续按“取含根的子区间”的方式细化 (这里取含根的左半区间 $[1, 2]$, 因 $f(1) < 0 = f(2)$), 则

$$k = 2: [1, 2], \quad x_2 = 1.5, \quad f(1.5) = -1.75 < 0 \Rightarrow [1.5, 2];$$

$$k = 3: [1.5, 2], \quad x_3 = 1.75, \quad f(1.75) = -0.9375 < 0 \Rightarrow [1.75, 2].$$

即迭代点列为 $x_1 = 2, x_2 = 1.5, x_3 = 1.75, \dots$ (此时左边端点已“贴住”根 2, 序列从左侧单调趋于 2).

收敛速度. 每次迭代区间长度减半, 因此第 k 步后

$$\|x_k - x^*\| \leq \frac{b_0 - a_0}{2^k} = \frac{2}{2^k} = 2^{1-k},$$

故二分法是线性收敛 (Q -线性, 也是 R -线性), 收敛比为 $\frac{1}{2}$: 每迭代一次误差上界减半, 约迭代 3.32 次可提高一位十进制精度 (每 10 次约提高 3 位), 但收敛速度与 f 的光滑性无关. 本题中由于 $x_1 = 2$ 恰为根, 第一步即收敛 (这属于特殊情形).

3. 三分法求单峰 (凸) 函数的极值

算法 (三分法). 设 f 在 $[a, b]$ 上连续且严格单峰 (即存在唯一的极小点 $x^* \in (a, b)$, f 在 $[a, x^*]$ 上严格单调减, 在 $[x^*, b]$ 上严格单调增), 取 $a_0 = a$, $b_0 = b$, 对 $k = 1, 2, \dots$

$$x_1^{(k)} = a_{k-1} + \frac{b_{k-1} - a_{k-1}}{3}, \quad x_2^{(k)} = a_{k-1} + \frac{2(b_{k-1} - a_{k-1})}{3};$$

若 $f(x_1^{(k)}) < f(x_2^{(k)})$, 则 $(a_k, b_k) = (a_{k-1}, x_2^{(k)})$; 否则 $(a_k, b_k) = (x_1^{(k)}, b_{k-1})$.

当 $(b_k - a_k) < \varepsilon$ 时停止, 取 $x^* \approx (a_k + b_k)/2$ (或 $\arg \min\{f(x_1), f(x_2)\}$). 原理: 设 $a < x_1 < x_2 < b$, 且 f 在 $[a, x^*]$ 上严格递减, 在 $[x^*, b]$ 上严格递增 (即严格单峰). 若 $f(x_1) < f(x_2)$, 则极小点不可能满足 $x^* > x_2$: 事实上, 若 $x_2 < x^*$, 由于 f 在 $[a, x^*]$ 上严格递减且 $x_1 < x_2 < x^*$, 应有 $f(x_1) > f(x_2)$, 这与 $f(x_1) < f(x_2)$ 矛盾. 因此 $x^* \leq x_2$, 可以舍弃区间 $[x_2, b]$. 同理, 若 $f(x_1) > f(x_2)$, 则 $x^* \geq x_1$, 可以舍弃 $[a, x_1]$. (若 f 可微且严格凸, 也可用导数判别: $f'(x_1) > 0$ 时极小点满足 $x^* \leq x_1$, $f'(x_2) < 0$ 时 $x^* \geq x_2$, 因此也可以通过求解 $f'(x) = 0$ 来定位极小点 — 在能构造出导数变号区间时, 可对 f' 使用二分法. 但需注意: 这一做法与基于函数值比较的三分法并不是同一个迭代过程, 两者的区间缩减因子分别为 $\frac{1}{2}$ 与 $\frac{2}{3}$.)

对 $f(x) = x^2 - x$ 从 $[0, 3]$ 开始的前两步迭代. ($f(x) = x(x-1)$ 为开口向上的凸函数, 极小点 $x^* = \frac{1}{2}$, $f(\frac{1}{2}) = -\frac{1}{4}$.)

$$k = 1: \quad [0, 3], \quad x_1 = 0 + \frac{3-0}{3} = 1, \quad f(1) = 0; \quad x_2 = 0 + \frac{2(3-0)}{3} = 2, \quad f(2) = 2.$$

因 $f(x_1) = 0 < 2 = f(x_2)$, 舍去右段, 得 $[a_1, b_1] = [0, 2]$.

$$k = 2: \quad [0, 2], \quad x_1 = \frac{2}{3}, \quad f\left(\frac{2}{3}\right) = \frac{4}{9} - \frac{2}{3} = -\frac{2}{9}; \quad x_2 = \frac{4}{3}, \quad f\left(\frac{4}{3}\right) = \frac{16}{9} - \frac{4}{3} = \frac{4}{9}.$$

因 $-\frac{2}{9} < \frac{4}{9}$, 舍去右段, 得 $[a_2, b_2] = \left[0, \frac{4}{3}\right]$, 其中 $x^* = \frac{1}{2} \in [0, \frac{4}{3}]$. (若再迭代一步: $x_1 = \frac{4}{9}$, $f = -\frac{20}{81}$; $x_2 = \frac{8}{9}$, $f = -\frac{8}{81}$; $-\frac{20}{81} < -\frac{8}{81}$, 故得 $\left[0, \frac{8}{9}\right]$.)

收敛速度. 每步区间长度乘以 $\frac{2}{3}$, 故第 k 次迭代后区间长度为

$$L_k = \left(\frac{2}{3}\right)^k L_0, \quad L_0 = b_0 - a_0.$$

若取区间中点作为近似值, 则误差满足更精确的估计

$$|x_k - x^*| \leq \frac{1}{2} \left(\frac{2}{3}\right)^k L_0 = \frac{3}{2} \left(\frac{2}{3}\right)^k,$$

即线性收敛, 收敛比为 $\frac{2}{3}$. (若直接用区间长度作估计, 即 $|x_k - x^*| \leq L_k = 3 \left(\frac{2}{3}\right)^k$, 也并非错误, 只是误差界较松.) 此外, 三分法的收敛比 $\frac{2}{3}$ 比二分法的 $\frac{1}{2}$ 慢, 且每步需计算两个函数值, 故单位计算量的效率低于二分法.

注 (“上凸” 一词). 这里把 “上凸” 按 “函数图形向上弯曲 (即 (下) 凸, 单峰) 需极小化” 理解; 若函数是开口向下的凹 (上凸) 函数而要求极大值, 只需把上述两个函数值的比较方向反过来.

4. 一维简单迭代法解 $x^2 - \frac{x}{2} = 0$

方程即 $x \left(x - \frac{1}{2} \right) = 0$, 两个根为 $x^* = 0$ 与 $x^* = \frac{1}{2}$.

简单迭代法 (不动点迭代). 把方程改写为等价形式 $x = \varphi(x)$, 迭代

$$x_{k+1} = \varphi(x_k), \quad k = 0, 1, 2, \dots$$

(1) 取 $\varphi(x) = 2x^2$ (即由 $x^2 = \frac{x}{2}$ 两边乘 2 得 $x = 2x^2$). 以 $x_0 = 0.15$ 为初值:

$$x_1 = 2(0.15)^2 = 0.045, \quad x_2 = 2(0.045)^2 = 0.00405, \quad x_3 = 2(0.00405)^2 = 3.2805 \times 10^{-5};$$

继续迭代 $x_4 = 2.1523 \times 10^{-9}$, $x_5 = 9.2651 \times 10^{-18}$, ... 迭代收敛到 $x^* = 0$. 收敛性分析: $\varphi'(x) = 4x$, $\varphi'(0) = 0$, $|\varphi'(0)| < 1$, 故在 $x^* = 0$ 附近局部收敛; 又 $\varphi'(0) = 0$, $\varphi''(0) = 4 \neq 0$, 故收敛阶至少为 2 (实际上 $e_{k+1} = x_{k+1} - 0 = 2e_k^2$, 恰为二阶收敛). 注意 $|\varphi'(\frac{1}{2})| = 2 > 1$, 故另一个不动点 $\frac{1}{2}$ 不是吸引的: 除 $x_0 = \frac{1}{2}$ 这一特殊初值之外 (此时 $x_k \equiv \frac{1}{2}$, 迭代恒停留在不动点上), 从 $\frac{1}{2}$ 附近出发的迭代都会远离它. 因此更准确的说法是: 对题目所给初值 $x_0 = 0.15$, 该迭代格式收敛到 0, 且为二阶收敛; 但不能笼统地说它 “只能收敛到 0”.

(2) 取 $\varphi(x) = \sqrt{x/2}$ (由 $x^2 = \frac{x}{2}$ 开方, 取正根). 注意右端平方根要求 $x \geq 0$; 对应的不动点满足 $x^2 = \frac{x}{2}$, 即 $x = 0$ 或 $x = \frac{1}{2}$, 因此需结合所给初值分析实际迭代轨道所趋近的不动点. 当 $x_0 = 0.15$ 时, 迭代始终在非负区域中进行:

$$x_1 = \sqrt{0.075} = 0.2738613, \quad x_2 = \sqrt{0.1369306} = 0.3700414,$$

$$x_3 = \sqrt{0.1850207} = 0.4301403, \dots$$

迭代收敛到 $x^* = \frac{1}{2}$.

严格证明 ($x_0 = 0.15$ 确实落在收敛区域内). 仅由 $|\varphi'(x^*)| < 1$ 只能得到局部收敛, 还需说明题目所给初值确实落在收敛邻域中. 对 $0 < x < \frac{1}{2}$,

$$\sqrt{\frac{x}{2}} > x \iff \frac{x}{2} > x^2 \iff x < \frac{1}{2}, \quad \sqrt{\frac{x}{2}} < \frac{1}{2} \iff \frac{x}{2} < \frac{1}{4} \iff x < \frac{1}{2},$$

故

$$0 < x < \frac{1}{2} \implies x < \varphi(x) < \frac{1}{2}.$$

由于 $x_0 = 0.15 \in \left(0, \frac{1}{2}\right)$, 由归纳法得

$$0 < x_0 < x_1 < x_2 < \dots < \frac{1}{2},$$

即 $\{x_k\}$ 单调递增且有上界 $\frac{1}{2}$, 从而收敛. 设 $x_k \rightarrow L$, 则由 φ 的连续性,

$$L = \lim_{k \rightarrow \infty} x_{k+1} = \lim_{k \rightarrow \infty} \varphi(x_k) = \varphi(L) = \sqrt{\frac{L}{2}},$$

即 $L^2 = \frac{L}{2}$, 解得 $L = 0$ 或 $L = \frac{1}{2}$; 又 $L \geq x_0 > 0$, 故

$$L = \frac{1}{2}, \quad \text{即} \quad x_k \uparrow \frac{1}{2} \quad (k \rightarrow \infty).$$

收敛速度: $\varphi'(x) = \frac{1}{4\sqrt{x/2}}$, $\left|\varphi'\left(\frac{1}{2}\right)\right| = \frac{1}{2} < 1$, 故线性收敛, 收敛比为 $\frac{1}{2}$ (误差每步约减半: $x_1 - \frac{1}{2} = -0.2261$, $x_2 - \frac{1}{2} = -0.1300$, $x_3 - \frac{1}{2} = -0.0699$, 比值约为 0.5).

结论. 同一个方程的等价改写方式不同, 得到的迭代格式收敛性也不同: $\varphi(x) = 2x^2$ 收敛到根 0 (且为二阶收敛), $\varphi(x) = \sqrt{x/2}$ 收敛到根 $\frac{1}{2}$ (线性收敛, 比为 $\frac{1}{2}$). 这正体现了简单迭代法的关键: 要使 $|\varphi'(x^*)| < 1$, 且 $|\varphi'(x^*)|$ 越小收敛越快.

5. Q - p 阶收敛 $\Rightarrow R$ - p 阶收敛

记 $\mathbf{e}_k = \mathbf{x}_k - \mathbf{x}^*$.

定义 (Q -阶收敛). 若存在 $p \geq 1$ 与常数 $C \geq 0$ (当 $p = 1$ 时要求 $C < 1$), 使得当 k 充分大时

$$\|\mathbf{e}_{k+1}\| \leq C \|\mathbf{e}_k\|^p,$$

则称该迭代法具有 Q - p 阶收敛速度 (等价地, $\limsup_{k \rightarrow \infty} \|\mathbf{e}_{k+1}\| / \|\mathbf{e}_k\|^p < \infty$; 当 $p = 1$ 时还要求 $\limsup_{k \rightarrow \infty} \|\mathbf{e}_{k+1}\| / \|\mathbf{e}_k\| < 1$).

定义 (R -阶收敛). 若存在一个 Q - p 阶收敛的非负数列 $\{y_k\}$ (即 $y_{k+1} \leq Cy_k^p$), 使得

$$\|\mathbf{x}_k - \mathbf{x}^*\| \leq y_k$$

对充分大的 k 成立, 则称 $\{\mathbf{x}_k\}$ 具有 R - p 阶收敛速度, 即 $\{\mathbf{x}_k\}$ 的误差能被一个 Q - p 阶收敛的数列控制 (故 R -阶收敛也称为根收敛速度). 与之等价的定量刻画是根收敛因子

$$R_p\{\mathbf{x}_k\} = \begin{cases} \limsup_{k \rightarrow \infty} \|\mathbf{e}_k\|^{1/k}, & p = 1, \\ \limsup_{k \rightarrow \infty} \|\mathbf{e}_k\|^{1/p^k}, & p > 1, \end{cases}$$

当 $R_p\{\mathbf{x}_k\} < 1$ 时即可保证 $\{\mathbf{x}_k\}$ 具有 R - p 阶收敛速度; 反向地, 按“控制数列”定义具有 R - p 阶收敛速度也蕴含 $R_p\{\mathbf{x}_k\} < 1$. 因此上述两种定义等价 (两个方向分别证明如下).

证明. 需要证明三件事: (i) Q - p 阶收敛 $\Rightarrow R_p\{\mathbf{x}_k\} < 1$; (ii) 存在 Q - p 阶控制数列 $\Rightarrow R_p\{\mathbf{x}_k\} < 1$; (iii) $R_p\{\mathbf{x}_k\} < 1 \Rightarrow$ 存在 Q - p 阶控制数列. 三者合起来即得两种 R -阶收敛定义的等价性, 以及对一切 $p \geq 1$ 的 Q - $p \Rightarrow R$ - p . (注意不能简单地“取 $y_k = \|\mathbf{e}_k\|$ ”: 控制数列的定义只要求存在某个 Q - p 阶数列控制误差, 并不要求误差序列 $\{\|\mathbf{e}_k\|\}$ 本身满足 Q - p 阶条件 — 本段末尾的注给出了 R - p 阶收敛但误差序列本身不是 Q - p 阶的例子.)

(i) Q - p 阶收敛 $\Rightarrow$ 根收敛因子 < 1 . 设 $p > 1$, 由 Q - p 阶收敛, 存在 $C > 0$ 与 k_0 , 使得 $\|\mathbf{e}_{k+1}\| \leq C \|\mathbf{e}_k\|^p$ ($k \geq k_0$). 令

$$\gamma = C^{\frac{1}{p-1}} (> 0), \quad \text{于是 } C = \gamma^{p-1}.$$

下面用归纳法证明: 对一切 $k \geq k_0$,

$$\|\mathbf{e}_k\| \leq \frac{1}{\gamma} (\gamma \|\mathbf{e}_{k_0}\|)^{p^{k-k_0}}. \quad (**)$$

$k = k_0$ 时右端为 $\frac{1}{\gamma} \cdot \gamma \|e_{k_0}\| = \|e_{k_0}\|$, 成立. 设 $(**)$ 对 k 成立, 则

$$\|e_{k+1}\| \leq C \|e_k\|^p \leq \gamma^{p-1} \left[\frac{1}{\gamma} (\gamma \|e_{k_0}\|)^{p^{k-k_0}} \right]^p = \gamma^{p-1} \gamma^{-p} (\gamma \|e_{k_0}\|)^{p^{k+1-k_0}} = \frac{1}{\gamma} (\gamma \|e_{k_0}\|)^{p^{k+1-k_0}},$$

归纳完成. 于是当 $k \geq k_0$ 时

$$\|e_k\|^{1/p^k} \leq \left(\frac{1}{\gamma} \right)^{1/p^k} (\gamma \|e_{k_0}\|)^{p^{-k_0}} \xrightarrow{k \rightarrow \infty} (\gamma \|e_{k_0}\|)^{1/p^{k_0}},$$

故

$$R_p\{\mathbf{x}_k\} = \limsup_{k \rightarrow \infty} \|e_k\|^{1/p^k} \leq (\gamma \|e_{k_0}\|)^{1/p^{k_0}}.$$

由于 $\|e_{k_0}\| \rightarrow 0$ ($k_0 \rightarrow \infty$), 可取 k_0 充分大使 $\gamma \|e_{k_0}\| < 1$, 从而 $R_p\{\mathbf{x}_k\} < 1$, 即具有 R - p 阶收敛速度.

$p = 1$ 的情形: 由 $\|e_{k+1}\| \leq C \|e_k\|$ ($C < 1$) 得 $\|e_k\| \leq C^{k-k_0} \|e_{k_0}\|$, 于是

$$R_1\{\mathbf{x}_k\} = \limsup_{k \rightarrow \infty} \|e_k\|^{1/k} \leq C < 1,$$

即具有 R -线性收敛速度.

(ii) 控制数列 $\Rightarrow$ 根收敛因子 < 1 . 设 $\{y_k\}$ 为非负数列, 且对充分大的 k 有

$$\|e_k\| \leq y_k, \quad y_{k+1} \leq C y_k^p \quad (C > 0).$$

当 $p > 1$ 时, 把 (i) 中已证的结论用于数列 $\{y_k\}$ (它以同一常数 C 满足 Q - p 阶条件), 得

$$\limsup_{k \rightarrow \infty} y_k^{1/p^k} < 1.$$

又由 $0 \leq \|e_k\| \leq y_k$ 知, 对充分大的 k 有 $\|e_k\|^{1/p^k} \leq y_k^{1/p^k}$, 于是

$$R_p\{\mathbf{x}_k\} = \limsup_{k \rightarrow \infty} \|e_k\|^{1/p^k} \leq \limsup_{k \rightarrow \infty} y_k^{1/p^k} < 1.$$

当 $p = 1$ 时, 由 $y_{k+1} \leq C y_k$ ($0 \leq C < 1$) 得 $y_k \leq C^{k-k_0} y_{k_0}$, 从而 $\|e_k\| \leq C^{k-k_0} y_{k_0}$, 故

$$R_1\{\mathbf{x}_k\} = \limsup_{k \rightarrow \infty} \|e_k\|^{1/k} \leq C < 1.$$

因此控制数列定义 $\Rightarrow$ 根收敛因子定义.

(iii) 根收敛因子 $< 1 \Rightarrow$ 存在控制数列. 设 $p > 1$ 且

$$R_p\{\mathbf{x}_k\} = \limsup_{k \rightarrow \infty} \|e_k\|^{1/p^k} = \rho < 1.$$

任取 $\rho < q < 1$. 由上极限的定义, 存在 k_1 , 使得当 $k \geq k_1$ 时 $\|e_k\|^{1/p^k} \leq q$, 即

$$\|e_k\| \leq q^{p^k}.$$

令 $y_k := q^{p^k}$ ($k \geq k_1$), 则

$$y_{k+1} = q^{p^{k+1}} = (q^{p^k})^p = y_k^p,$$

即 $\{y_k\}$ 本身就是一个 Q - p 阶收敛的非负数列, 并且 $\|e_k\| \leq y_k$. 故按“控制数列”的定义, $\{x_k\}$ 具有 R - p 阶收敛速度.

$p = 1$ 的情形同理: 若 $R_1\{x_k\} = \limsup_{k \rightarrow \infty} \|e_k\|^{1/k} = \rho < 1$, 任取 $\rho < q < 1$, 则对充分大的 k 有 $\|e_k\| \leq q^k$; 令 $y_k := q^k$, 则 $y_{k+1} = qy_k$ ($q < 1$), 即 $\{y_k\}$ 是 Q -线性收敛数列且控制 $\{e_k\}$, 故 $\{x_k\}$ 具有 R -线性收敛速度.

两种定义的等价性. 综合 (ii) 与 (iii), 对一切 $p \geq 1$,

$$\{x_k\} \text{ 具有 } R\text{-}p \text{ 阶收敛速度} \iff R_p\{x_k\} < 1 \iff \begin{cases} \exists \{y_k\}, y_k \geq 0, \|x_k - x^*\| \leq y_k; \\ y_{k+1} \leq Cy_k^p \end{cases}$$

(上面两式均对充分大的 k 成立.) 即“ $\{x_k\}$ 具有 R - p 阶收敛速度”, “ $R_p\{x_k\} < 1$ ”与“存在 Q - p 阶控制数列”三者等价; 再由 (i), 对一切 $p \geq 1$ 都有 Q - p 阶收敛 $\Rightarrow R$ - p 阶收敛. $\square$

注 (序列本身未必是 Q - p 阶的). R -阶收敛比 Q -阶收敛弱: 它只要求存在 Q - p 阶收敛的控制数列, 而不要求误差序列 $\{\|e_k\|\}$ 本身满足 Q - p 阶条件. 例如取 $\|e_k\| = \frac{\rho^{2^k}}{k+1}$ ($0 < \rho < 1$), 则 $R_2\{x_k\} = \lim_{k \rightarrow \infty} \rho(k+1)^{-1/2^k} = \rho < 1$, 即具有 R -二阶收敛速度; 但

$$\frac{\|e_{k+1}\|}{\|e_k\|^2} = \frac{\rho^{2^{k+1}}/(k+2)}{\rho^{2^k}/(k+1)^2} = \frac{(k+1)^2}{k+2} \rightarrow \infty,$$

不满足 Q -二阶收敛. 故 Q - p 阶 $\Rightarrow R$ - p 阶; 但反之 (由 R - p 阶推出误差序列本身 Q - p 阶) 不成立.

6. Newton 法与割线法解 $x^2 - 4 = 0$

Newton 法 ($x_0 = 1$):

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} = x_k - \frac{x_k^2 - 4}{2x_k} = \frac{1}{2} \left(x_k + \frac{4}{x_k} \right).$$

迭代过程:

k	0	1	2	3	4	5
x_k	1	2.5	2.05	2.0006097561	2.0000000929	2.0000000000000002
$x_k - 2$	-1	0.5	0.05	6.098×10^{-4}	9.292×10^{-8}	2.2×10^{-15}

误差满足 $e_{k+1} = \frac{e_k^2}{2x_k} \rightarrow \frac{1}{4}e_k^2$, 故为二阶 (平方) 收敛, 收敛常数 $\frac{1}{2 \cdot 2} = \frac{1}{4}$.

割线法 ($x_0 = 0, x_1 = 1$):

$$x_{k+1} = x_k - f(x_k) \frac{x_k - x_{k-1}}{f(x_k) - f(x_{k-1})}, \quad f(x) = x^2 - 4.$$

迭代过程:

k	0	1	2	3	4	5
x_k	0	1	4	1.6	$\frac{13}{7} \approx 1.8571429$	2.0165289
$x_k - 2$	-2	-1	2	-0.4	-0.1428571	1.653×10^{-2}
k	6	7	8	9		
x_k	1.9993904	1.9999975	2.0000000004	2.0		
$x_k - 2$	-6.096×10^{-4}	-2.509×10^{-6}	3.8×10^{-10}	≈ 0		

(第一步: $f(0) = -4$, $f(1) = -3$, 割线为 $y = x - 4$, 零点在 $x = 4$, 故 $x_2 = 4$ 是一个较大的“过冲”; 此后迅速收敛.) 割线法的收敛阶为 $\varphi = \frac{1+\sqrt{5}}{2} \approx 1.618$ (超线性收敛), 比 Newton 法略慢, 但每步只需一个函数值, 不需要导数.

7. 古巴比伦法就是 Newton 法, 且至少平方收敛

求 $\sqrt{3}$ 的古巴比伦 (开方) 迭代为

$$x_{k+1} = \frac{1}{2} \left(x_k + \frac{3}{x_k} \right). \quad (1)$$

而对方程 $f(x) = x^2 - 3 = 0$ 用 Newton 法:

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)} = x_k - \frac{x_k^2 - 3}{2x_k} = \frac{2x_k^2 - x_k^2 + 3}{2x_k} = \frac{1}{2} \left(x_k + \frac{3}{x_k} \right), \quad (2)$$

与 (1) 完全一致. 故古巴比伦法就是求解 $x^2 - 3 = 0$ 的 Newton 法. $\square$

先说明初值条件: 若希望迭代收敛到正根 $+\sqrt{3}$, 应取 $x_0 > 0$; 若 $x_0 < 0$, 则相应收敛到 $-\sqrt{3}$; 若 $x_0 = 0$, 迭代式没有定义.

至少平方收敛. 记 $\alpha = \sqrt{3}$, $e_k = x_k - \alpha$. 由 (2),

$$e_{k+1} = x_{k+1} - \alpha = \frac{x_k^2 + 3}{2x_k} - \alpha = \frac{x_k^2 - 2\alpha x_k + \alpha^2}{2x_k} = \frac{(x_k - \alpha)^2}{2x_k} = \frac{e_k^2}{2x_k}. \quad (3)$$

若 $x_0 > 0$, 则由算术-几何平均值不等式 $x_{k+1} = \frac{1}{2} \left(x_k + \frac{3}{x_k} \right) \geq \sqrt{3} > 0$, 故一切 $x_k > 0$ (事实上 $x_k \geq \sqrt{3}$, $k \geq 1$), 于是由 (3)

$$|e_{k+1}| = \frac{e_k^2}{2x_k} \leq \frac{1}{2\sqrt{3}} e_k^2,$$

即至少平方收敛 (二阶收敛), 收敛常数为 $\lim_{k \rightarrow \infty} \frac{|e_{k+1}|}{e_k^2} = \frac{1}{2\sqrt{3}} = \frac{\sqrt{3}}{6} \approx 0.2887$. $\square$

补充. $x_0 > 0$ 时还有单调性: $x_k \geq \sqrt{3}$ ($k \geq 1$) 且 $x_{k+1} - x_k = \frac{3 - x_k^2}{2x_k} \leq 0$ ($k \geq 1$), 即从第二步起 $\{x_k\}$ 单调递减且有下界 $\sqrt{3}$, 故收敛. 例如 $x_0 = 1$: $x_1 = 2$, $x_2 = 1.75$, $x_3 = 1.7321429$, $x_4 = 1.7320508100$, $x_5 = 1.7320508076 = \sqrt{3}$ (机器精度内).

8. 简化 Newton 法解 $x^2 - 4 = 0$

简化 Newton 法 (平行弦法): 把导数固定在初值处不再改变,

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_0)} = x_k - \frac{f(x_k)}{M}, \quad M := f'(x_0) \neq 0.$$

本题 $f(x) = x^2 - 4$, $x_0 = 1$, $M = f'(1) = 2$, 故

$$x_{k+1} = x_k - \frac{x_k^2 - 4}{2} = 2 + x_k - \frac{x_k^2}{2}.$$

前三步 (并多算几步以便观察):

k	0	1	2	3	4	5	6	7
x_k	1	2.5	1.375	2.4296875	1.4779968	2.3857595	1.5398353	2.3542889
$x_k - 2$	-1	0.5	-0.625	0.4296875	-0.5220032	0.3857595	-0.4601647	0.3542889

即 $x_1 = 2.5$, $x_2 = 1.375$, $x_3 = 2.4296875$. 可见迭代点在根的两侧来回跳动, 且 $|x_k - 2|$ 下降得很慢 (这是下面要说明的临界现象).

一般收敛性定理. 设 $f(x^*) = 0$, $f'(x^*) \neq 0$, $M = f'(x_0) \neq 0$. 迭代函数 $g(x) = x - \frac{f(x)}{M}$ 满足

$$g'(x^*) = 1 - \frac{f'(x^*)}{M} = 1 - \frac{f'(x^*)}{f'(x_0)} =: c.$$

由 $e_{k+1} = g(x_k) - g(x^*) = g'(\xi_k)e_k$ (ξ_k 介于 x_k 与 x^* 之间, g' 连续) 得误差的一阶递推

$$e_{k+1} = ce_k + O(e_k^2),$$

其中 c 是有符号的线性系数 (其符号决定误差是否交替变号); 而通常所说的线性收敛比 (渐近收敛因子) 应取 c 的绝对值, 记为

$$q = \left| 1 - \frac{f'(x^*)}{f'(x_0)} \right| = \left| 1 - \frac{f'(x^*)}{M} \right|.$$

若 $q < 1$, 则对充分小的 $\varepsilon > 0$, 当 $|e_k| < \varepsilon$ 时 $|e_{k+1}| \leq (q + \varepsilon)|e_k|$, 即简化 Newton 法局部线性收敛, 收敛因子为 q ($c > 0$ 时误差保持同号, $c < 0$ 时误差符号交替变化, 但收敛因子都是 $|c| = q$). (特别地, 当 $M = f'(x^*)$ 时 $c = q = 0$, 退化为 Newton 法, 二阶收敛.)

本题的临界情形. 这里 $f'(x^*) = f'(2) = 4$, $M = f'(1) = 2$, 于是有符号线性系数

$$c = 1 - \frac{4}{2} = -1, \quad \text{线性收敛因子} \quad q = \left| 1 - \frac{4}{2} \right| = 1,$$

恰好取到临界值, 上述线性收敛条件 $q < 1$ 不成立, 故 “至少线性收敛” 这一结论对本题所给初值并不成立. 事实上 $g'(2) = -1$, $x^* = 2$ 是 g 的抛物型 (中性) 不动点: 由

$$e_{k+1} = x_{k+1} - 2 = -(x_k - 2) - \frac{1}{2}(x_k - 2)^2 = -e_k - \frac{1}{2}e_k^2$$

可算出

$$e_{k+2} = e_k - \frac{1}{2}e_k^3 + O(e_k^4).$$

令 $u_j = e_{2j}^2$ (偶数步误差的平方), 则由上式

$$u_{j+1} = e_{2j+2}^2 = \left(e_{2j} - \frac{1}{2}e_{2j}^3 + O(e_{2j}^4) \right)^2 = e_{2j}^2 - e_{2j}^4 + O(e_{2j}^5) = u_j - u_j^2 + O(u_j^{5/2}),$$

于是

$$\frac{1}{u_{j+1}} - \frac{1}{u_j} = \frac{u_j - u_{j+1}}{u_j u_{j+1}} = \frac{u_j^2 + O(u_j^{5/2})}{u_j^2 + O(u_j^3)} \rightarrow 1,$$

从而 $u_j \sim \frac{1}{j}$, 即

$$|e_{2j}| \sim \frac{1}{\sqrt{j}} \quad (j \rightarrow \infty),$$

由于 $k = 2j$, 即 $j \sim k/2$, 于是整体误差满足

$$|e_k| \sim \sqrt{\frac{2}{k}}, \quad \text{特别地} \quad |e_k| = O(k^{-1/2}),$$

即误差只是按 $k^{-1/2}$ 的速度趋于零, 比任何线性收敛都要慢 (迭代仍收敛, 但为次线性收敛, 而不是通常意义下的线性收敛).

要使命题成立应作的修正. 只要保证

$$q = \left| 1 - \frac{f'(x^*)}{f'(x_0)} \right| < 1$$

(即 $f'(x_0)$ 与 $f'(x^*)$ 同号且 $f'(x^*)/f'(x_0) \in (0, 2)$), 简化 Newton 法就局部线性收敛, 收敛因子为 q , 此时 “至少线性收敛” 的结论成立. 例如

- 取 $x_0 = 2.5$ (先作一步 Newton 法), $M = f'(2.5) = 5$, 则有符号系数 $c = 1 - \frac{4}{5} = \frac{1}{5}$, 收敛因子 $q = \left| 1 - \frac{4}{5} \right| = \frac{1}{5} = 0.2 < 1$, 线性收敛;
- 若 $c = 1 - \frac{f'(x^*)}{f'(x_0)} = -\frac{1}{2}$, 则误差符号交替变化, 但收敛因子仍为 $q = \frac{1}{2}$;
- 取 $M = f'(x^*) = 4$: 此时 $c = q = 0$, 迭代函数在 x^* 处的一阶导数为零, 因而二阶收敛. 需要强调: 这仍然是简化 Newton 法 (导数被固定为常数 4), 而不是标准 Newton 法 (详见下面的注).

注 ($M = f'(x^*)$ 仍是简化 Newton 法, 而不是标准 Newton 法). 简化 Newton 法的定义是

$$x_{k+1} = x_k - \frac{f(x_k)}{M},$$

其中 M 在整个迭代过程中保持不变. 即使取 $M = f'(x^*)$, 导数仍是一个固定常数, 得到的仍是简化 Newton 法; 而标准 Newton 法的分母 $f'(x_k)$ 随 k 变化, 二者并不相同. 以本题为例: 取 $M = f'(x^*) = 4$ 时迭代为 $x_{k+1} = x_k - \frac{x_k^2 - 4}{4}$, 令 $e_k = x_k - 2$, 则

$$e_{k+1} = x_{k+1} - 2 = x_k - 2 - \frac{x_k^2 - 4}{4} = e_k - \frac{(x_k - 2)(x_k + 2)}{4} = e_k - \frac{e_k(e_k + 4)}{4} = -\frac{1}{4}e_k^2,$$

故确实二阶收敛, 且二阶收敛常数为

$$\lim_{k \rightarrow \infty} \frac{|e_{k+1}|}{|e_k|^2} = \frac{1}{4};$$

而标准 Newton 法为 $x_{k+1} = x_k - \frac{x_k^2 - 4}{2x_k}$ (分母 $f'(x_k) = 2x_k$ 随 k 变化), 两者不同. 一般地, 若 $M = f'(x^*)$, 则 $g'(x^*) = 1 - \frac{f'(x^*)}{M} = 0$; 再若 $f \in C^2$ 且 g 在 x^* 附近足够光滑, 则

$$e_{k+1} = \frac{g''(x^*)}{2}e_k^2 + O(e_k^3),$$

从而简化 Newton 法二阶收敛. 因此正确的说法是

$$M = f'(x^*) \implies \text{简化 Newton 法二阶收敛},$$

而不是 “ $M = f'(x^*) \implies$ 标准 Newton 法”. 总之: 题中 “简化 Newton 法至少线性收敛” 的结论应在 $|1 - f'(x^*)/f'(x_0)| < 1$ 的前提下叙述; 本题数据使该量恰等于 1, 属于需要单独分析的临界情形.

9. 解非线性方程组 $F(\mathbf{x}) = 0$ 的 Newton 法与拟 Newton 法

设 $F: D \subset \mathbb{R}^m \rightarrow \mathbb{R}^m$ Fréchet 可微, $F'(\mathbf{x})$ 为 Jacobi 阵.

(一) Newton 法. 迭代格式:

$$\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} - [F'(\mathbf{x}^{(k)})]^{-1} F(\mathbf{x}^{(k)}).$$

算法过程: 给定初值 $\mathbf{x}^{(0)}$, 对 $k = 0, 1, 2, \dots$

1. 计算 $F(\mathbf{x}^{(k)})$ 与 Jacobi 阵 $F'(\mathbf{x}^{(k)})$;
2. 解线性方程组 $F'(\mathbf{x}^{(k)})\Delta\mathbf{x}^{(k)} = -F(\mathbf{x}^{(k)})$ (实际计算中不求逆矩阵, 而用 LU 分解);
3. 令 $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \Delta\mathbf{x}^{(k)}$;
4. 若 $\|F(\mathbf{x}^{(k+1)})\|$ (或 $\|\Delta\mathbf{x}^{(k)}\|$) 满足精度要求则停止, 否则 $k \leftarrow k+1$ 返回第 1 步.

收敛性: 若 $F'(\mathbf{x}^*)$ 非奇异, F' 在 $\mathbf{x}^*$ 的邻域内 Lipschitz 连续, 则存在邻域 S , 当 $\mathbf{x}^{(0)} \in S$ 时迭代有定义且局部二阶 (Q -二阶) 收敛:

$$\|\mathbf{x}^{(k+1)} - \mathbf{x}^*\| \leq c \|\mathbf{x}^{(k)} - \mathbf{x}^*\|^2.$$

特点: 收敛快, 但每次迭代都要计算 m^2 个偏导数并解一个 m 阶线性方程组, 代价高; 当 Jacobi 阵奇异或病态, 或初值离解太远时可能失败 (可用阻尼 Newton 法, 同伦延拓等补救).

(二) 拟 Newton 法 (Quasi-Newton Method). 基本思想: 不逐次计算 $F'(\mathbf{x}^{(k)})$, 而用一个容易更新的矩阵 B_k 近似它 (或用 $H_k = B_k^{-1}$ 直接近似 Jacobi 阵的逆), 并利用迭代中已获得的信息 (差商) 自动修正 B_k , 使其满足割线方程 (拟 Newton 条件)

$$B_{k+1}\mathbf{s}_k = \mathbf{y}_k, \quad \mathbf{s}_k = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}, \quad \mathbf{y}_k = F(\mathbf{x}^{(k+1)}) - F(\mathbf{x}^{(k)}).$$

其含义是: 新的近似 Jacobi 阵沿方向 $\mathbf{s}_k$ 的作用与差商一致, 即 $B_{k+1} \approx \frac{\mathbf{y}_k \mathbf{s}_k^T}{\mathbf{s}_k^T \mathbf{s}_k}$ 在 $\mathbf{s}_k$ 方向上精确.

Broyden 秩 1 修正公式:

$$B_{k+1} = B_k + \frac{(\mathbf{y}_k - B_k \mathbf{s}_k) \mathbf{s}_k^T}{\mathbf{s}_k^T \mathbf{s}_k} \quad (\text{Broyden 第一公式}),$$

$$H_{k+1} = H_k + \frac{(\mathbf{s}_k - H_k \mathbf{y}_k) \mathbf{s}_k^T H_k}{\mathbf{s}_k^T H_k \mathbf{y}_k} \quad (\text{Broyden 第二公式, 直接更新逆矩阵近似}).$$

可以验证: 第一公式给出的 B_{k+1} 满足割线方程, 且在 Frobenius 范数意义下是“满足割线方程, 且对 B_k 改变最小”的修正 (最小改变性质).

算法过程: 给定 $\mathbf{x}^{(0)}$ 与 B_0 (常取 $B_0 = F'(\mathbf{x}^{(0)})$ 或 $B_0 = I$), $H_0 = B_0^{-1}$, 对 $k = 0, 1, 2, \dots$

1. 求搜索方向: 解 $B_k \mathbf{d}_k = -F(\mathbf{x}^{(k)})$, 或直接算 $\mathbf{d}_k = -H_k F(\mathbf{x}^{(k)})$;
2. 作线搜索 (或取 $\alpha_k = 1$ 作全步长): $\mathbf{x}^{(k+1)} = \mathbf{x}^{(k)} + \alpha_k \mathbf{d}_k$. 注意 F 是向量值函数, 不能直接写 $F(\mathbf{x}^{(k+1)}) < F(\mathbf{x}^{(k)})$, 而应引入标量 merit function $\Phi(\mathbf{x}) = \frac{1}{2} \|F(\mathbf{x})\|_2^2$ (其梯度为 $\nabla \Phi(\mathbf{x}) = F'(\mathbf{x})^T F(\mathbf{x})$), 并要求 $\Phi(\mathbf{x}^{(k+1)}) < \Phi(\mathbf{x}^{(k)})$, 或使用 Armijo 型条件 $\Phi(\mathbf{x}^{(k)} + \alpha_k \mathbf{d}_k) \leq \Phi(\mathbf{x}^{(k)}) + c \alpha_k \nabla \Phi(\mathbf{x}^{(k)})^T \mathbf{d}_k$ ($0 < c < 1$) 来保证目标函数得到充分下降; 但必须指出: 拟 Newton 方向 $\mathbf{d}_k = -H_k F(\mathbf{x}^{(k)})$ 并不自动满足下降性条件 $\nabla \Phi(\mathbf{x}^{(k)})^T \mathbf{d}_k < 0$, 因此不能仅凭“加入 Armijo/Wolfe 条件”就断言 Broyden 方法全局收敛; 若要建立全局收敛定理, 需将拟 Newton 法与基于 merit function 的线搜索或信赖域策略结合, 并附加下降方向条件, 有界性条件以及 Jacobi 正则性等假设;

3. 计算 $\mathbf{s}_k = \mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}$, $\mathbf{y}_k = \mathbf{F}(\mathbf{x}^{(k+1)}) - \mathbf{F}(\mathbf{x}^{(k)})$;

4. 按 Broyden 公式更新 $\mathbf{B}_{k+1}$ (或 $\mathbf{H}_{k+1}$); 若满足精度则停止, 否则 $k \leftarrow k + 1$.

收敛性: 在 $\mathbf{F}'(\mathbf{x}^*)$ 非奇异, $\mathbf{F}'$ Lipschitz 连续等条件下, Broyden 方法 (取 “好” 的修正) 局部 Q -超线性收敛 (Dennis–Moré 定理):

$$\lim_{k \rightarrow \infty} \frac{\|\mathbf{x}^{(k+1)} - \mathbf{x}^*\|}{\|\mathbf{x}^{(k)} - \mathbf{x}^*\|} = 0,$$

并且不需要计算 Jacobi 阵与各阶偏导数. 关于每步运算量, 需要区分具体实现: 若显式维护逆 Jacobi 近似 $\mathbf{H}_k \approx \mathbf{F}'(\mathbf{x}^{(k)})^{-1}$, 则矩阵-向量乘法与秩 1 修正等主要操作只需 $O(m^2)$ 次运算; 若直接维护 $\mathbf{B}_k$, 并在每一步对稠密矩阵重新作一般 LU 分解来求解 $\mathbf{B}_k \mathbf{d}_k = -\mathbf{F}(\mathbf{x}^{(k)})$, 则朴素实现的运算量为 $O(m^3)$ (若利用 Sherman–Morrison 公式对秩 1 更新后的矩阵作递推求解, 也可把每步降到 $O(m^2)$). 因此不能无条件地声称 Broyden 方法每步都是 $O(m^2)$; 正确的表述是: 若显式维护逆 Jacobi 近似 $\mathbf{H}_k$, 则单步更新与方向计算主要为 $O(m^2)$; 若直接维护稠密 $\mathbf{B}_k$ 并在每步重新作一般线性求解, 则朴素实现通常需 $O(m^3)$. 与 Newton 法的比较也应作条件性描述: Broyden 方法避免了每一步重新构造完整的 Jacobi 阵, 并在适当实现下可以降低单步线性代数开销, 因而在 Jacobi 阵构造代价较高或问题维数较大时可能具有明显优势; 但其实际总计算成本还取决于函数值计算, 线性求解, 迭代次数以及线搜索等因素, 不能仅由 $O(m^2) < O(m^3)$ 就断言它在所有情况下都优于 Newton 法.

其他常用变形: 用差商代替偏导数的离散 (有限差分) Newton 法; 对称情形 (最优化问题) 中保持对称正定性的秩 2 修正, 如 DFP, BFGS 公式; 大规模问题的有限内存 BFGS (L-BFGS); 以及信赖域型拟 Newton 方法等.